2026년도 머신러닝 1주차 과제

AI 개발 수행내역서

과제명	대규모 금융 트랜잭션 불균형 데이터 대응 및 AI 기반 이상 탐지(FDS) 분류 모델 개발 [초안]
담당자	홍승현

2026년 4 월 3일

AI개발 수행내용

1. 사업과제 : 대규모 금융 트랜잭션 불균형 데이터 대응 및 AI 기반 이상 탐지 (FDS) 분류 모델 개발

2. 개요 및 현황

2.1 추진배경 및 목적

○ 금융기관에 장기간 축적된 거래 데이터가 존재함에 따라, 비대면 채널에서 거래의 신뢰성을 보강하기 위한 머신러닝 기반 위험도 산출 및 탐지 수요가 확대

○ 지능화된 매크로 송금 및 계정 탈취 등 사기 수법이 고도화됨에 따라, 고정 규칙(Rule-based)만으로는 한계가 있으며, 데이터로부터 패턴을 학습하는 이상거래 탐지(FDS) 체계가 요구

○ 극심한 불균형을 가진 신용카드 거래(공개 벤치마크) 를 분석하고, SMOTETomek으로 Train만 증강한 뒤 앙상블 분류기로 사기 확률을 산출. 실제 운영 시스템의 실시간 차단이 아니라, 동일한 전처리·평가 절차 하에서 모델을 비교·시연하는 것을 목표로 한다

2.2 과제 범위

과제구분			내용
AI	AI 기반 금융 사기 탐지(FDS) 분류 모델 구현	데이터셋 구축	Kaggle Creditcard 공개 로그(유럽 카드사 결제) 수집·정리
		데이터 전처리·정규화	RobustScaler 적용, 입력 변수 상관관계 히트맵 작성
		클래스 불균형 해소	분할 후 Train에만 SMOTETomek 적용, Test는 미증식·원 불균형 유지
		모델 학습·선정	2-Track 비교·분석(노트북 등) 후, 저장·시연용 모델은 XGBoost로 선정
		성능·오탐·미탐 점검	Recall·F2-Score·PR-AUC 등으로 오탐·미탐과의 균형 검토
		설명 가능 AI(XAI)	XGBoost 단건 예측에 대해 SHAP 워터폴로 변수별 기여 해석
		시연·프로토타입	Streamlit에서 위험도·지표 확인, 임계값 조정에 따른 시나리오 시연
시각화	탐지 결과 및 성능 비교 시각화		데이터 분포 시각화(클래스 불균형·리샘플링 전후)
			Hold-out 성능 비교 시각화(혼동행렬·주요 지표)
			XAI 시각화(SHAP·사기 판별 근거)
			Streamlit 대시보드(탐지 결과·임계값 조절)

2.3 과제 추진 방법

1) 구축 대상 선정 기준

○ 데이터 신뢰성 및 재현성

■ Kaggle Creditcard 등 국제적으로 많이 쓰이는 공개 벤치마크(약 28만 건)로, 동일 전처리·분할·지표로 실험 재현이 가능 여부

■ 금융기관 내부 원장 전체가 아니라, 불균형·탭형 거래 데이터에 대한 FDS 프로토타입 파이프라인을 검증하기에 적합 여부

■ Time, Amount 등 해석 가능한 변수와, 이미 비식별·차원 축소된 특성(V1 ~ V28) 이 함께 제공되어 이상거래(사기) 분류에 사용 가능 여부

○ 불균형 데이터 및 적용 기법

■ 정상 대비 사기 비율이 극도로 낮은(대략 정상 ~99.8%·사기 ~0.17% 수준) 불균형이 있어, Train에 한한 SMOTETomek(오버샘플링+경계 정리 결합) 적용이 적합 여부

■ 정확도만으로는 설명이 어려운 환경에서 Recall·PR-AUC·F2 등으로 미탐·오탐 동시 평가 여부

○ 데이터 형태 및 비식별 연구 활용

■ 직접 식별자 없이 제공되는 마스킹·차원 축소 특성(V1 ~ V28) 과 Time, Amount 등이 함께 제공되어 공개 데이터 기반 FDS 연구·재현에 적합 여부

■ 본 과제 범위에서 외부 운영 시스템·실거래 인프라와의 연동 없이 로컬/시연 환경에서 패턴 학습·평가를 수행하기에 충분 여부

2) AI 예측 분석모델 적용 대상

시스템 적용 범위	공개 데이터	예측모델인자(독립변수)	AI예측 분석 대상
비대면 거래에 대한 위험도 스코어링·탐지 지원 (프로토타입/시연)	- Kaggle Creditcard 공개 로그 (유럽 카드holder, 약 2일, 총 284,807건)	- 거래 고유 변수 : 시간 주기 특성(Time_sin / Time_cos), Amount(스케일링 등 전처리) - 비식별 보안 변수 : 익명화된 주성분 변수(V1 ~ V28)	- 이상거래(Fraud) 이진 분류 - Class (0: 정상, 1: 사기) - 사기 확률(스코어) 산출 및 임계값에 따른 오탐·미탐 트레이드오프 검토

3) AI 분석모델 구축 프로세스

연구개발 주요 결과물

1. 데이터 수집

- Kaggle Credit Card Fraud Detection 데이터 (CSV) 284,807건
- https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud

	Time	Amount	Class	V1	V2	V3	V4	V5	V6	V7	V8	V9	V10	V11	V12	V13	V14
2	10765	8	0	-0.30632	0.794015	1.767337	-0.67501	0.039556	-0.31608	0.33689	-0.05978	0.68996	-0.89917	2.136549	-1.47209	2.706664	1.432008
3	18489	21.99	0	-1.54441	0.192998	0.67199	-0.62573	1.953606	0.231276	-0.01792	0.125894	1.19821	-0.72231	0.789475	-3.035	0.568386	1.287709
4	19914	5	0	1.405693	-0.45506	0.640889	-0.24835	-1.06802	-0.78404	-0.68229	-0.22092	0.912998	0.136482	0.275076	-3.08936	1.213983	1.05926
5	25208	7.3	0	-1.92445	1.582919	-0.31336	-2.90643	2.267501	3.153706	0.398868	0.587037	1.481131	1.907915	0.074545	-0.35702	-0.14162	-0.8136
6	27255	0	0	1.248804	0.047208	0.423388	-0.13952	-0.59222	-0.98065	-0.04242	-0.12304	-0.08896	-0.03444	1.704529	1.074219	0.09154	0.451779
7	31944	1170	0	-2.29093	-2.57857	-0.3069	0.61881	-3.81479	2.482192	3.293415	0.441752	-0.12338	-1.71159	-1.56911	-0.9281	-0.19017	0.233115
8	33184	15.56	0	0.951961	0.416024	0.788296	2.341854	0.471227	1.333706	-0.15288	0.445539	-0.85856	0.457759	0.857263	0.718679	0.449485	0.323364
9	34118	76	0	1.453447	-0.97469	-0.13496	-1.41855	-1.05775	-0.94885	-0.46114	-0.35084	-2.14915	1.4041	-0.75852	-0.79507	0.834501	-0.16929
10	34897	8	0	1.331935	-0.39731	-0.11311	-0.69717	-0.57256	-0.70396	-0.17446	-0.12372	-1.42988	0.860998	1.581395	0.53885	-0.14306	0.624942
11	35181	0.89	0	1.214692	0.245851	0.309292	0.584285	-0.38636	-0.76711	-0.0743	-0.00872	-0.10002	-0.08878	1.48723	0.477046	-0.69641	0.075485
12	35484	31	0	1.39959	-0.5907	0.168619	-1.02995	-0.53981	0.040444	-0.71257	0.002299	-0.97175	0.756801	0.543827	0.112453	1.075384	-0.24577
13	36721	12.31	0	1.142349	0.090803	0.198756	1.031747	-0.58085	-0.62864	-0.28634	0.127945	0.560734	-0.55871	1.222848	0.092665	-1.9157	-1.03296
14	38238	380	0	-1.57263	0.612082	0.129682	-1.29043	-1.68131	0.188992	1.968965	0.081226	-0.44264	-0.75769	0.764797	0.391447	-0.17297	0.466562
15	38671	150.92	0	0.935768	-0.86388	0.965979	0.373065	-1.40666	-0.35306	-0.51479	0.060357	1.303544	-0.49607	-0.92077	0.178562	-0.7585	-0.37228
16	39394	281.94	0	-2.15194	-2.37882	1.904957	-2.28725	-0.33062	-0.97111	-0.06753	0.251995	2.391839	-2.6812	-0.59542	0.892896	-0.72211	-0.47807
17	41505	364.19	1	-16.5265	8.584972	-18.6499	9.505594	-13.7938	-2.8324	-16.7017	7.517344	-8.50706	-14.1102	5.299236	-10.834	1.67112	-9.37386
18	42145	17.33	0	-0.63611	1.236421	1.189131	0.676485	0.111772	-0.10726	0.642491	0.17567	-0.56416	0.416173	1.539318	0.493868	-0.55585	0.562179
19	42272	37.73	0	0.925523	-0.68796	1.015057	-0.05942	-0.33952	1.98513	-1.03381	0.776725	0.885371	-0.49563	1.907331	1.779557	0.082448	-0.28383
20	43985	101.19	0	-1.68217	0.341439	1.287377	-1.00005	-0.92961	0.037511	0.321687	0.254967	1.778829	0.140253	-0.97607	-0.20651	-1.33711	-0.73801
21	43994	53.5	0	-0.53679	0.545234	-0.15406	-1.05205	2.405064	3.556153	0.307192	0.931851	-0.34351	-0.37108	-0.48988	-0.16073	-0.19649	0.130012
22	44261	520.12	0	0.339812	-2.74375	-0.13407	-1.38573	-1.45141	1.015887	-0.52438	0.22406	0.899746	-0.56501	-0.08767	0.979427	0.076883	-0.21788
23	45102	26.88	0	-0.94068	0.903703	0.978734	-0.43772	0.876943	1.047219	0.859711	-0.24089	0.607975	0.867774	0.181979	0.37654	0.071096	-0.73203
24	49848	21.95	0	1.104574	-0.54013	1.127897	0.019039	-1.08371	0.308094	-0.91705	0.377067	0.969331	-0.2425	1.112838	0.731945	-0.97192	-0.03438
25	52840	69	0	-1.92939	-0.69317	1.197647	-2.36525	-1.3834	2.47E-05	-1.37881	1.077452	-2.68164	0.443854	0.526857	-0.51592	0.043383	0.296375
26	52913	0.89	0	0.676855	1.587029	-1.50815	1.443815	1.31679	-1.16034	1.149049	-0.41939	-0.09057	-0.32306	2.967921	-0.15503	-0.71777	-3.70928
27	54263	0.76	0	-0.25511	1.062676	0.521598	0.599852	0.660175	-1.16714	0.74838	-0.13967	-1.06528	-0.6023	1.916162	0.651058	0.336313	-0.92896
28	55575	22.7	0	-3.41942	-1.13008	1.607086	2.229979	2.644089	-0.79354	1.088242	-1.00841	-0.93332	1.921982	1.954445	0.38884	0.301474	-0.42787
29	56803	1	0	1.173609	0.511603	-0.52045	1.122626	0.358867	-0.29596	0.025005	0.144442	-0.11018	-0.51336	1.500906	-0.22873	-1.57033	-0.83968
30	58084	34.99	0	1.230866	0.095267	0.257008	0.535814	-0.31462	-0.70776	0.061866	-0.15429	0.150024	-0.06594	-0.74508	-0.05631	-0.0855	0.3152

2. 데이터 분석

2.1 트랜잭션 데이터 상관관계 및 불균형 분석 (EDA)

○ 파이 차트로 Class(정상/사기) 비율을 확인하고, 사기 비중이 매우 낮은(약 0.17%) 극단적 불균형 확인

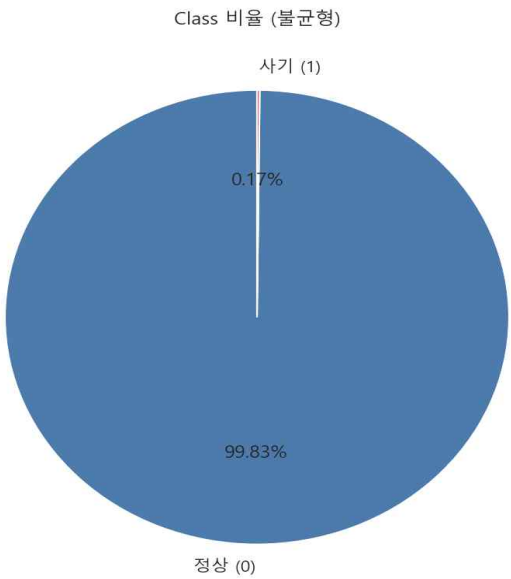

[그림 2]

○ 상관관계 히트맵을 통해 V1~V28, Amount 등 입력 변수와 Class 사이의 선형 상관 강도를 탐색적으로 확인하고, 사기 여부와 함께 움직이는 경향이 상대적으로 큰 변수를 참고.

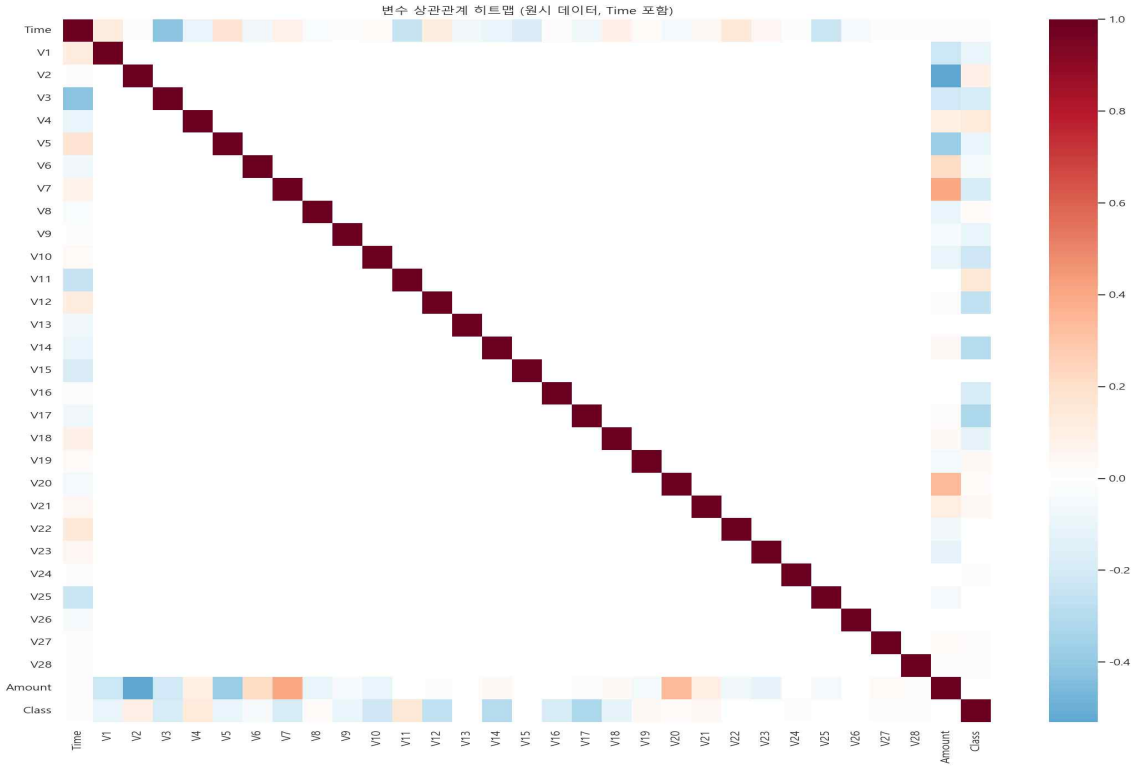

[그림 3] 원시 데이터(또는 지정 변수) 기준 상관행렬. 빨간/파란 계열은 양/음의 상관

○ 사기 탐지 모델링을 위한 핵심 대상 설정 : 거래 금액(Amount) 및 비식별 주요 변수군

○ 시간(Time) 변수 및 핵심 보안 변수 패턴 분석

- 시간대별 사기 발생 분포(KDE)를 시각화한 결과, 원본 Time 변수는 첫 거래로부터 누적된 초(Seconds) 수치이므로 모델이 특정 시점에만 과적합(Overfitting)될 수 있는 노이즈 위험성이 있음을 진단함

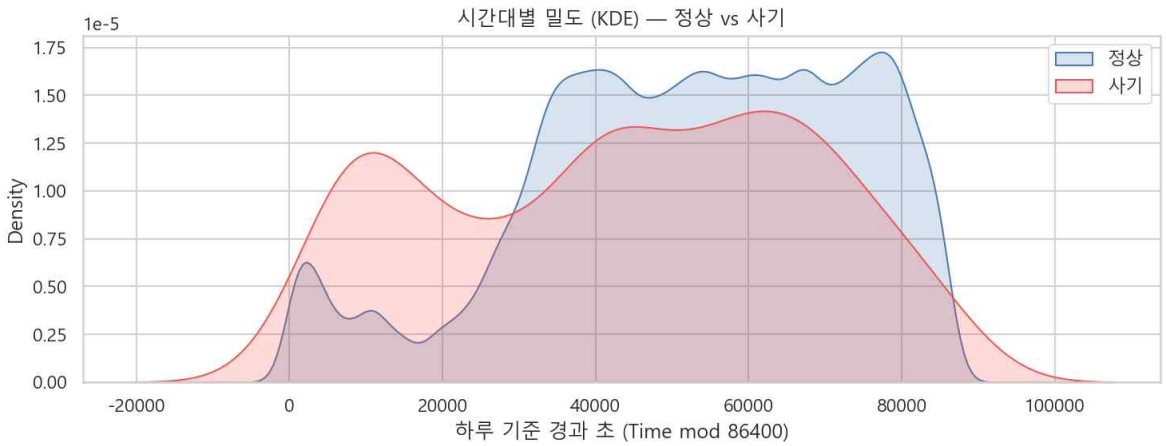

[그림 4]

- 상관계수가 높은 핵심 V변수의 정상/사기 데이터 분포도(KDE)를 비교하여 뚜렷한 확인 및 비교

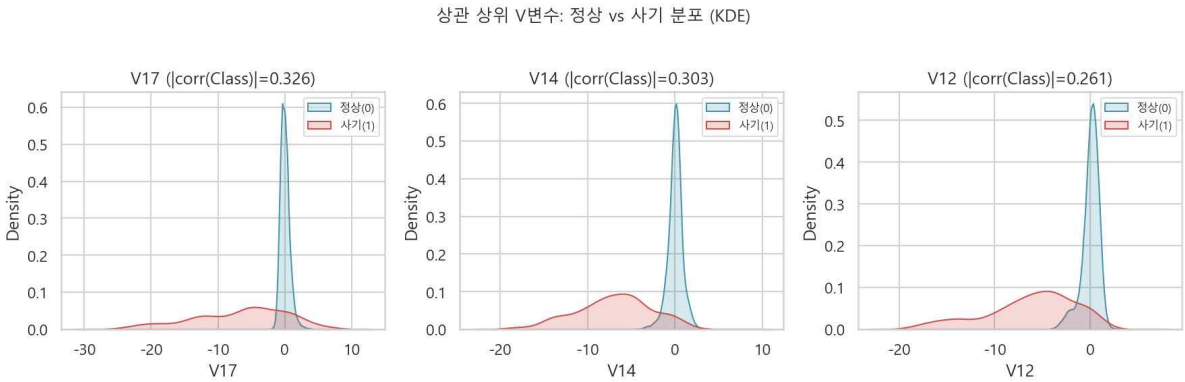

[그림 5]

2.2 탐색적 데이터 분석

○ 결측치 및 중복값 점검

- 보안 통제된 V1 ~ V28 변수의 결측치(Missing Value) 완전 무결성(0건) 확인

○ 결제 금액(Amount) 극단치 분석 및 전처리

- Class(정상·사기)별 Amount 박스플롯(로그 축 권장) 으로 고액 꼬리·극단값이 많이 존재함을 확인
- Amount에 RobustScaler 적용으로 극단 금액 영향 완화

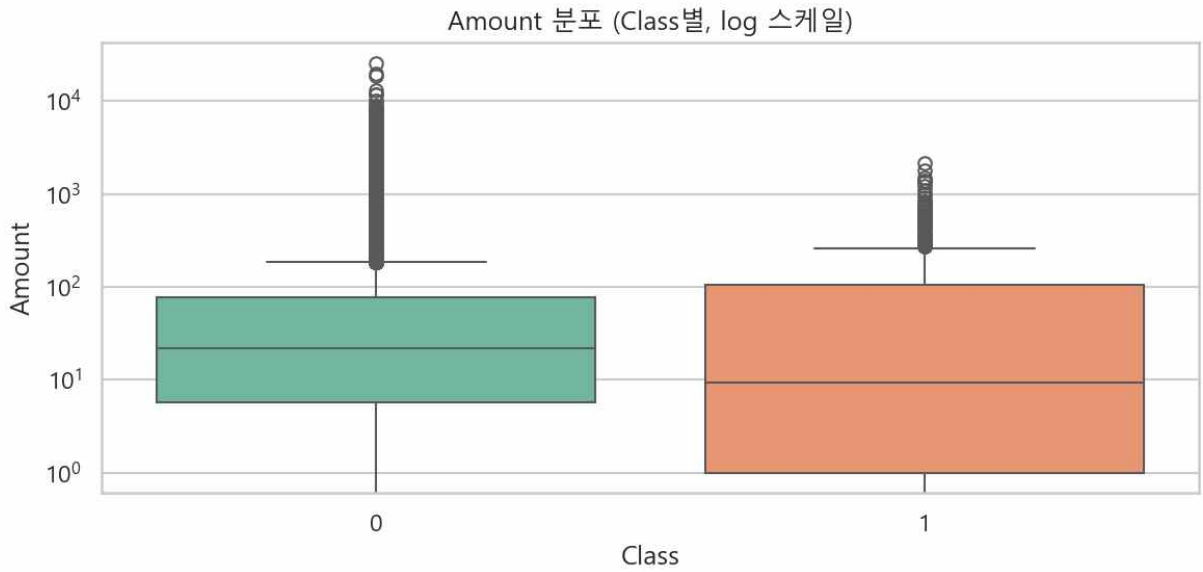

[그림 6]

- 극단 금액으로 인한 스케일 왜곡을 줄이기 위해 Amount에 RobustScaler를 적용
- 적용 전·후 히스토그램으로 금액 변수의 수치 범위가 압축·완화됨을 확인

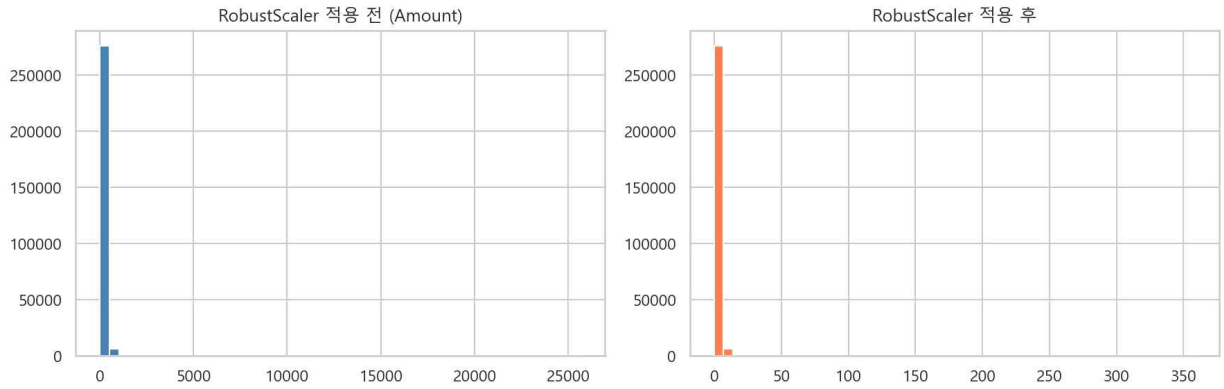

[그림 7] Amount RobustScaler 적용 전·후 분포

○ 데이터 전처리 및 피쳐 엔지니어링

- Amount 극단치 통제를 위해 이상치에 강한 RobustScaler 적용

『RobustScaler 적용 전/후 금액 분포는 그림 7과 같다.』

- 앞서 진단한 Time 변수의 단순 누적 초(Seconds)가 유발하는 노이즈를 방지하기 위해 원본 변수는 삭제. 대신 하루(86400초) 기준의 삼각함수(sin, cos) 변환을 수행하여, 심야 시간대 사기 집중 등 시간의 주기성(Cyclicality) 패턴을 파생 변수로 생성하여 대체

『정상/사기의 시간대별 밀도(KDE)는 그림 4와 같으며, 이에 따라 원본 Time 대신 주기적 파생 변수를 사용.』

- SMOTETomek으로 Train 불균형을 완화. PCA 2D로 보면 증식 후 소수 클래스가 조밀해지고 경계 부근이 상대적으로 덜 뭉개진 것처럼 보이는 것을 확인

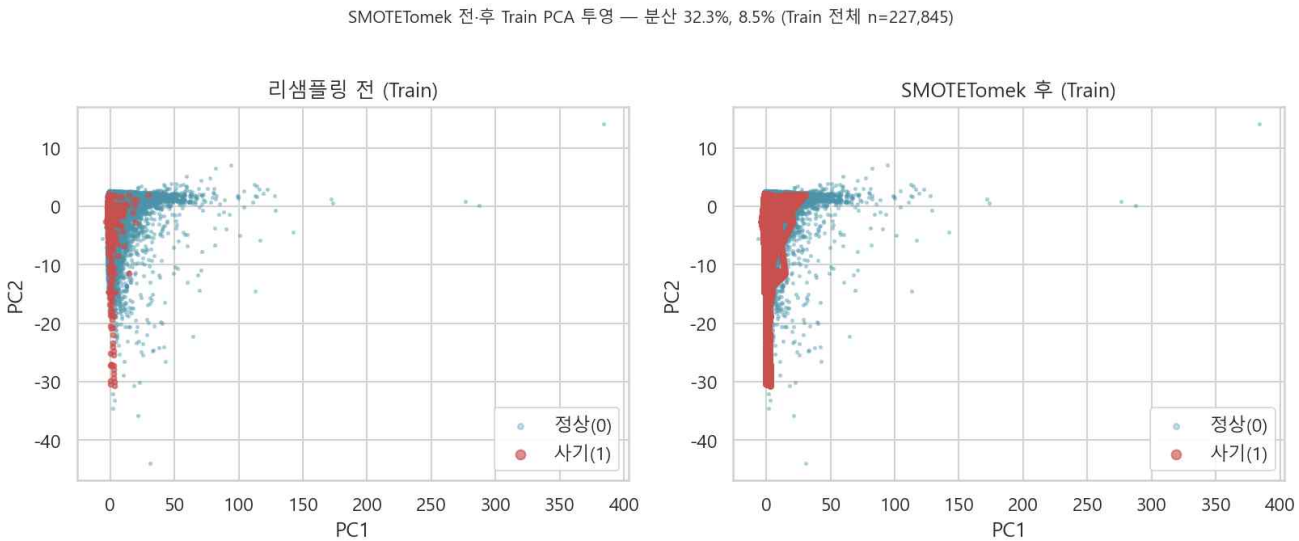

[그림 8]

- SMOTETomek 적용 전·후 Train 클래스 건수를 막대그래프로 비교하여, 소수 클래스가 다수 클래스와 유사한 규모로 맞춰진(약 1:1) 리샘플링 결과를 시각적으로 확인

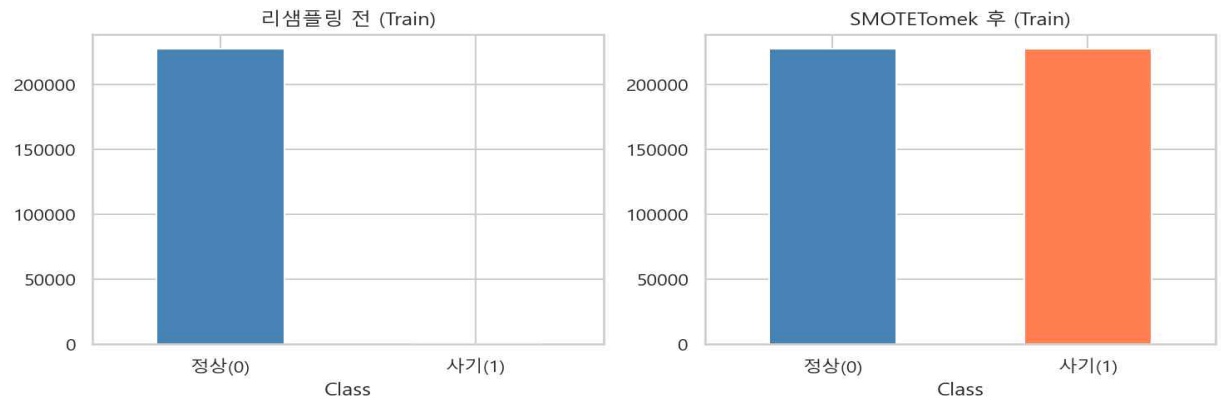

[그림 9]

- SMOTETomek 적용 전·후 Train의 (동일 조건) 상관 히트맵을 나란히 제시
- 불균형이 큰 상태에서는 정상 쪽 신호가 상대적으로 강해 변수 간 상관이 약하게 보이는 경향 확인
- 리샘플링 후에는 클래스 구성이 바뀌며 상관 패턴의 대비가 커져 탐색적 해석·가독성이 좋아짐을 확인

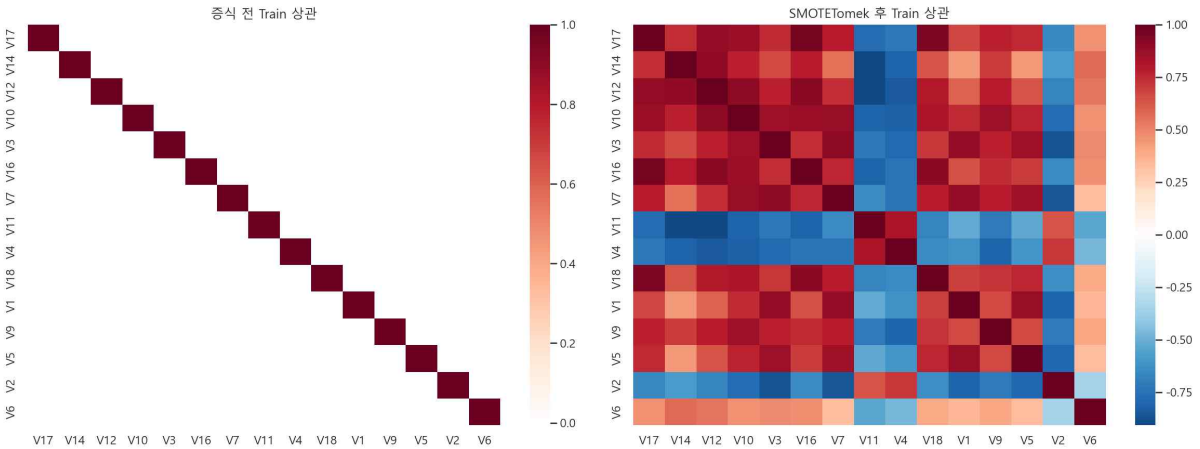

[그림 10]

3. 데이터 학습 및 모델 정의

3.1 모델정의 및 컴파일

○ 동일 전처리·SMOTETomek으로 증식한 Train으로 RandomForest·XGBoost를 각각 학습하고, 동일 Test (미증식·원 불균형)에서 성능을 비교하는 2-Track 실험 설계를 [그림 11]과 같이 정리
「다만 ,재현용 학습·추론 코드(fds_pipeline.py) 및 Streamlit에는 비교 후 선정한 XGBoost만 반영」

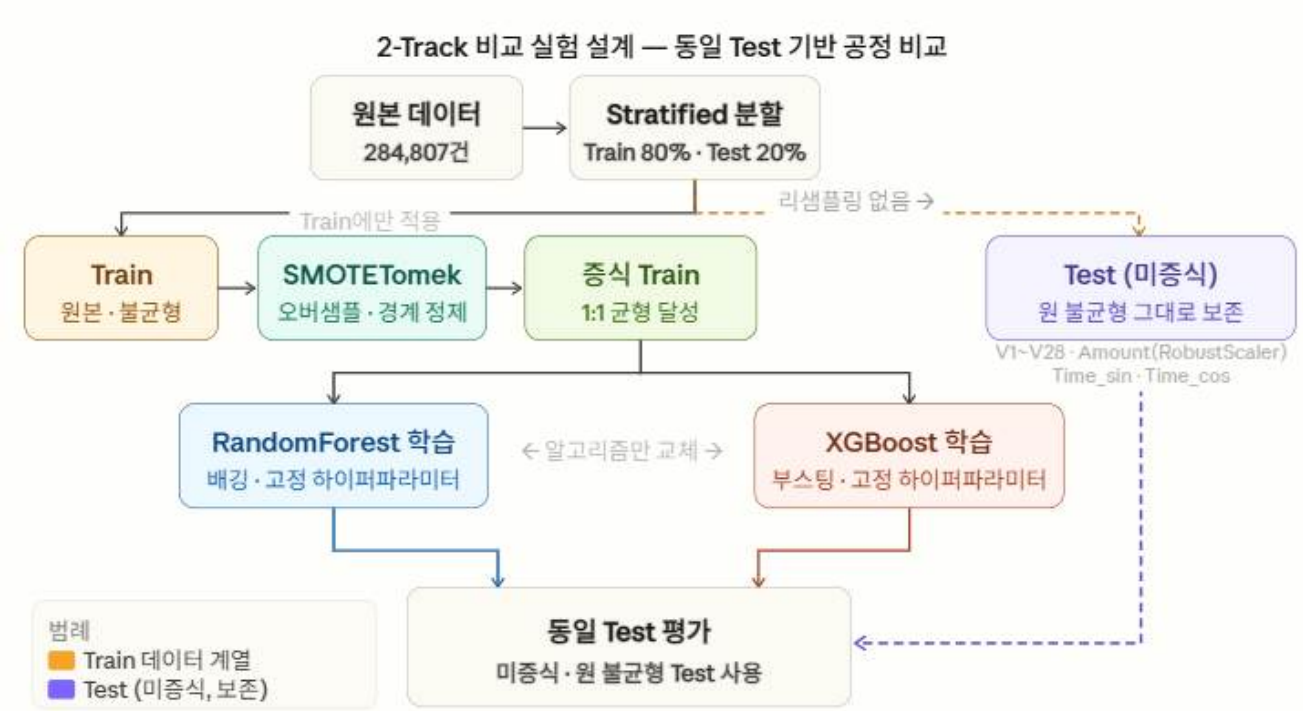

[그림 11]

○ 트리 앙상블의 두 축인 배깅(RandomForest: 병렬 학습·다수결로 분산 완화) 과 부스팅(XGBoost: 순차 학습·잔차 보정으로 편향 완화) 원리를 개념적으로 대비하여, 이후 2-Track 비교에서 기대할 수 있는 학습·오차 성향 차이를 정리

[그림 12]

○ 하이퍼파라미터는 고정한 채, 증식된 Train 일부에서 학습 표본 크기를 단계적으로 키우며 3-fold 층화 CV로 Recall 학습곡선을 산출·비교

○ Train Recall과 CV Recall(평균) 의 간격·추세로 과적합 여부와 안정성을 참고 (소표본, 참고용)

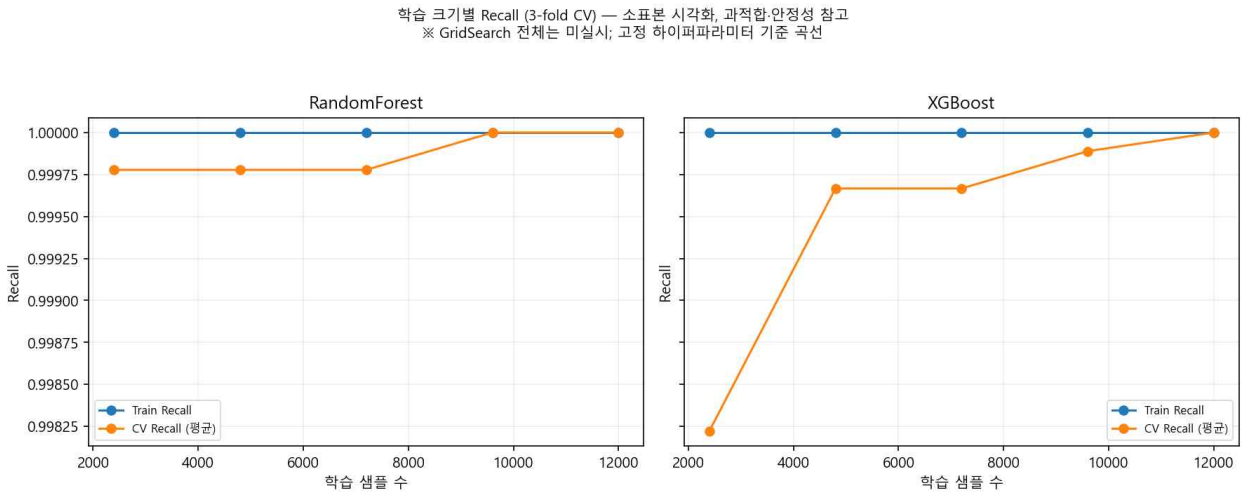

[그림 13]

3.2 모델학습 및 학습 시각화

○ 모델 학습

- SMOTETomek으로 증식된 Train으로 RandomForest·XGBoost를 각각 학습
  「2-Track, 동일 분할·전처리, 혼동행렬 등은 분석 산출물 기준」
- 하이퍼파라미터는 고정값으로 두고 학습한다 (GridSearchCV 미적용). 교차검증은 그림 13 학습곡선용 보조 실험에 한하며, 최종 모델 학습 전 과정 전체를 CV로 튜닝한 것은 아님.

○ 모델 판단 근거 시각화(XAI)

- SHAP(XAI)로 단건 트랜잭션에 대해 변수별 기여를 워터폴로 시각화하고, 사기 확률을 올린 변수와 낮춘 변수를 함께 해석. (배포·시연에 쓰는 XGBoost 기준)
- 학습에 쓰인 독립변수마다 방향(확률 상승/하락)과 상대적 크기를 한 화면에서 볼 수 있어 사후 검토·시연용 근거로 활용. (샘플이 바뀌면 막대 구성·최종값 달라짐, 전역 Feature Importance 와는 개념이 다름)

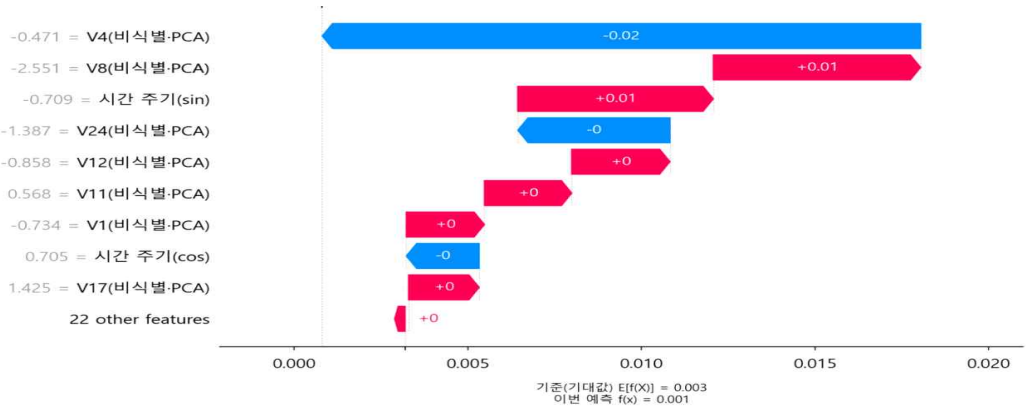

[그림 14] XGBoost 단건 예측에 대한 SHAP 워터폴

3.3 모델 예측 및 성능 평가

○ Test 예측 및 혼동행렬

- 동일 전처리·SMOTETomek Train으로 학습한 RandomForest·XGBoost를 동일 Test(원 불균형)에 적용하여 혼동행렬을 비교. (시연 앱은 XGBoost 단일 모델)
- 정상 다수·사기 소수 구조에서는 Accuracy만으로 성능을 요약하기 어렵다 판단, 미탐 비용이 큰 FDS 맥락에서 Recall을 핵심 참고 지표로 두고 오탐(FP)·미탐(FN) 패턴을 함께 해석.

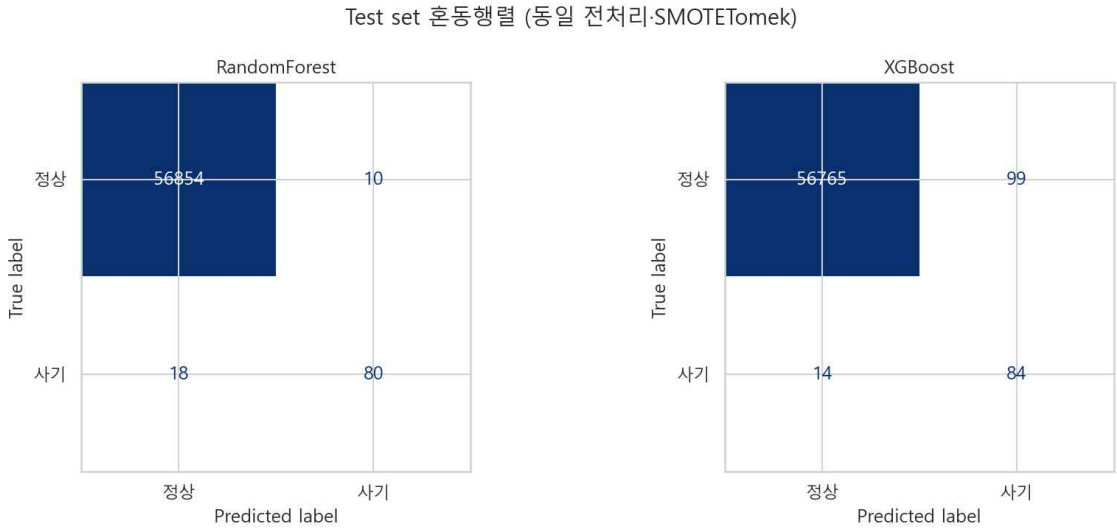

[그림 15]

○ Recall만 보면 오탐(FP) 부담이 가려질 수 있어, Recall에 더 큰 가중을 두는 F2-Score(β=2) 와 불균형에 민감한 PR-AUC를 함께 참고하여 성능을 점검. (혼동행렬의 FP/FN과 상호 보완)

3.4 대시보드 프로토타입 및 운영 시나리오 시연

○ AI-FDS Web 대시보드 (Streamlit, UI/UX)

- 범위: 실제 결제·인증 시스템과의 운영 연동은 아니며, 과제용 시연·프로토타입 화면 수준으로 다룸 세부 구현·UI는 4장「프로토타이핑(화면)」참고.
- 모델: 분석 단계에서 RandomForest와 XGBoost를 비교한 뒤, 저장·시연 모델은 XGBoost로 사용.
- 임계값: 슬라이더로 임계값을 바꾸면 동일 테스트셋에 대해 Recall·F2를 즉시 재계산해 표시.
- PR-AUC: 전체 테스트셋 사기 확률(y_prob) 로 정해지는 지표이므로 임계값과 무관, 고정 표시.
- 단건·XAI: 사이드바에서 정상/사기 유형을 고른 뒤 버튼으로 테스트셋에서 무작위 1건을 불러오고, 사기 확률과 SHAP 워터폴로 변수별 기여를 확인.

4. 프로토타이핑(화면)

4.1 FDS 대시보드 프로토타입(Streamlit)

○ FDS 대시보드 UI 구현 (Streamlit, 시연·프로토타입)

- Python Streamlit으로 구현하고, 학습된 XGBoost 분류기는 joblib 등으로 저장한 pkl을 불러와 앱 프로세스 안에서 추론. (별도 REST API 서버 없음)
- 임계값(Threshold) 슬라이더로 사기 확률(y_prob)와 비교한 예측(0/1)을 바꾼 뒤, 동일 테스트셋에 대해 Recall·F2를 다시 계산해 표시.
- PR-AUC는 전체 y_prob로 정해지는 값이라 임계값과 무관하게 동일하게 표시.

○ 테스트셋 단건 검증 데모

- 정상/사기 중 검증할 유형을 고른 뒤, 보유 X_test·y_test에서 해당 클래스를 무작위 1건 샘플링해 표시.
- 모델 사기 확률과 설정 임계값을 비교해 '정상 승인' / '사기 의심(차단 권고)' 등 메시지 표시.

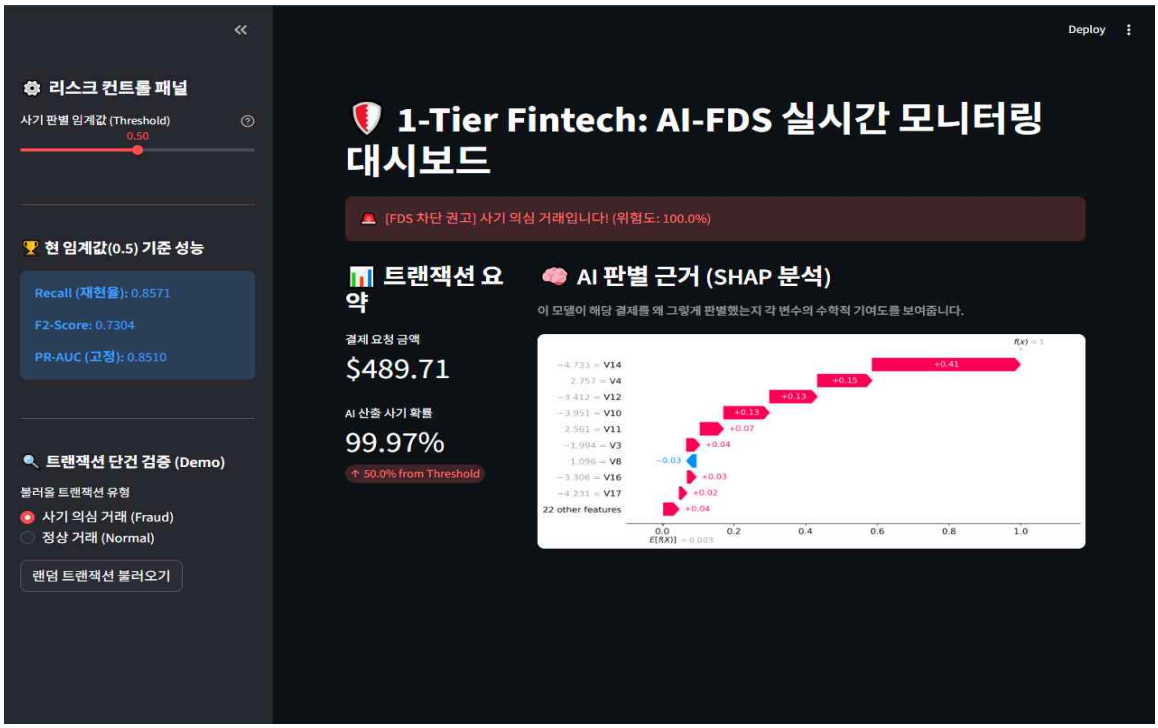

[그림 16]

4.2 AI 탐지 근거 시각화(XAI: 설명 가능한 AI)

○ SHAP(Shapley Additive Explanations) 워터폴

- 단건 트랜잭션에 대해 변수별 기여를 워터폴로 시각화.
- 사후 검토 시 기여 방향·크기를 화면에서 확인 가능.
- 실운영 이슈 처리 도구라기보다 설명·시연 목적에 가까움.
- 샘플이 바뀌면 워터폴도 달라지고, 전역 변수 중요도와는 다른 국소 설명.

5. 후기 및 결론

5.1 도입

○ 극단적 데이터 불균형의 한계 인지

- 99.8%가 정상 거래인 환경에서 기존의 '정확도(Accuracy)' 중심 평가가 가지는 통계적 착시와 한계를 명확히 인지.

○ 비즈니스 관점의 목표 재설정

- 단순 탐지율을 넘어 실제 금융 비즈니스의 미탐(재무 손실)과 오탐(고객 불편)비용을 동시에 고려하기 위해 Recall F2-Score, PR-AUC 등 비용 민감형 평가 지표로 분석 관점을 전환

5.2 배운 점

○ 도메인 지식을 반영한 피처 엔지니어링

- 선형적으로 누적되는 원시 Time 변수가 트리 모델에 과적합(Overfitting) 노이즈로 작용할 수 있음을 데이터(KDE)로 진단함.
  이를 단순 삭제에 그치지 않고, 심야 시간대 사기 집중이라는 범죄의 주기성(Cyclicality)을 담아내기 위해 삼각함수(sin, cos) 기반의 파생 변수로 변환하는 수학적 처리 방식을 적용함.

○ 데이터의 본질에 맞춘 전처리 체득

- 금액(Amount)의 극단치가 스케일을 왜곡하는 현상을 확인하고, 이상치에 강건한 RobustScaler를 적용하여 데이터 분포를 정제하는 실무적 전처리 기법의 중요성을 깊이 이해함.

5.3 모델 비교 및 해석

○ 하이브리드 리샘플링을 통한 한계 극복

- 단순 오버샘플링(SMOTE)이 유발하는 가짜 데이터 양산 부작용을 방지하기 위해, 언더샘플링이 결합된 SMOTETomek을 적용하여 소수 클래스를 증식함과 동시에 결정 경계의 노이즈를 정제함.

○ 블랙박스 모델의 해석력(XAI) 확보

- 고성능 앙상블 모델인 XGBoost를 최종 모델로 선정하고, SHAP TreeExplainer를 도입하여 단건 트랜잭션의 사기 차단 근거를 Waterfall 차트로 시각화함으로써 '설명 가능한 AI'의 실무적 가치를 확인함.

5.4 구현 및 시연

○ 파이프라인 분리를 통한 아키텍처 최적화

- 데이터 전처리 및 모델 학습 로직을 모듈화하여 단일 진실 소스(SSOT)를 구축함.
- 무거운 학습 과정은 로컬에서 1회 수행 후 아티팩트(.pkl)로 저장하고, Streamlit 웹 대시보드에서는 즉각적인 추론만 수행하도록 아키텍처를 경량화하여 실제 서비스 배포 환경과 유사한 시스템을 구현함.

5.5 한계 및 향후

○ 시간 외 검증(OOT) 부재 및 데이터 스코프의 한계

- 제공된 PCA 익명화 변수(V1~V28)에 의존하였으며, 과거 데이터로 미래를 예측하는 엄밀한 시계열 기반 교차 검증(Out-Of-Time Validation)을 완벽히 적용하지 못한 한계가 존재함.

○ 엔터프라이즈 아키텍처(MSA) 연동을 위한 향후 비전

- 현재의 Python 단일 모놀리식 구조를 넘어, 향후 실제 금융망 도입 시 기존 비즈니스 로직(승인/동결)을 처리하는 Java/Spring Boot 기반 코어 뱅킹 서버와 사기 확률 예측만 담당하는 Python/FastAPI 기반 마이크로서비스로 분리하고, 대규모 트래픽 처리를 위해 Kafka 등 메시지 큐를 연동하는 아키텍처로 고도화할 계획임.