MediCore
안과 CDSS

안저 이미지 기반 5개 질환 AI 진단 시스템

SH 모듈 담당 | 홍승현

FastAPI · Spring Boot · React

ONNX · PostgreSQL+pgvector · Gemini · LangGraph



정상 녹내장 백내장

DR 황반변성

목차 Contents

01–04
프로젝트 개요 & 아키텍처
문제 · 솔루션 · 시스템 구조 · 품질 검증

05–08
데이터 엔지니어링 & 모델 로드맵
Phase A→B · 데이터 출처 · 개발 전략

09–12
모델 개발 실험
백본 비교 · NB 실험 · KD · 버전 진화

13–14
최적화 & 시각화
Threshold · GradCAM 듀얼 모델

15–18
RAG & UI/UX
파이프라인 · 평가 · 소견서 SSE · 대시보드

19–24
성과 & 반성 & 미래
종합성과 · 트러블슈팅 · 부족한점 · 향후계획

문제 & 솔루션 Problem & Solution

⚠ 문제 인식

- 안과 전문의 부족 — 지역 불균형 심각
- 안저 촬영 후 판독 대기 시간 과다
- 5개 주요 질환(녹내장·백내장·DR·AMD·정상)
  개별 증상 패턴이 유사해 육안 감별 어려움
- 초기 발견 실패 시 실명 위험 증가

✓ 솔루션

AI 진단 보조

EfficientNet-B1 ONNX 모델, CPU 43.6ms 추론

RAG 소견서 생성

Hit@3 100% · MRR 0.92, Gemini 기반 의학 텍스트

5-Class 분류

Threshold 최적화 + Class-Adaptive KD

응급 자동 판정

Stage≥3 / 신뢰도≥88%+Stage≥2 / DR+65세+당뇨

Hit@3 → 3개 추천 중 정답 포함 확률

시스템 아키텍처 System Architecture

Frontend	Backend	AI/ML Layer
React (Vite)	FastAPI (Python)	EfficientNet-B1
Tailwind CSS	Spring Boot (Java)	LangGraph RAG
SSE Streaming	ONNX Runtime	Gemini API
Dashboard UI	PostgreSQL + pgvector	GradCAM

안저 이미지 업로드 → AI 진단 추론 (43.6ms) → RAG 소견서 생성 → 응급 판정 & 알림

9단계 Fail-Fast 품질 검증 파이프라인

01 이미지 형식 검증

PNG/JPG/TIFF

02 해상도 검사

≥512×512

03 채널 수 확인

RGB 3ch

04 밝기·대비 검사

히스토그램 분포

05 아티팩트 감지

블러·노이즈 탐지

06 안저 ROI 검출

원형 마스크 확인

07 전처리 정규화

CLAHE·리사이즈

08 모델 추론 실행

ONNX 43.6ms

09 신뢰도 임계 검사

Threshold 검증

데이터 엔지니어링 Phase A → Phase B

Phase A — 초기 접근	
백본	Swin-Base (88M 파라미터)
해상도	224 × 224
추론 속도	CPU 109ms
AMD Recall	0.1333 (심각한 미탐)
문제	대용량 모델 · 저해상도 · 메모리 OOM

Phase B — 최적화 완성	
백본	EfficientNet-B1 (7.8M 파라미터)
해상도	512 × 512 (고해상도)
추론 속도	CPU 43.6ms (↓60%)
AMD Recall	0.3778 (↑2.8배, 0.133→0.378)
개선	mmap + 전략적 캡핑 (정상 640+질환별 340) 해결

데이터 출처 Data Sources

녹내장 **ORIGA**

650장 · Glaucoma suspect

녹내장 **DRISHTI-GS**

101장 · Optic disc segmentation

백내장 **Cataract DS**

600+장 · Kaggle 공개 데이터셋

DR **APTOS 2019**

3,662장 · Diabetic Retinopathy

AMD **iChallenge**

400장 · Age-related Macular Deg.

정상/다목적 **DRIVE/CHASEDB**

~200장 · 혈관 분할 기반

** 전략적 캡핑: 정상 640장 + 질환별 340장 = 총 2,000장 베이스라인 (메모리 OOM 방지) / mmap 로딩 적용*

모델 개발 로드맵 Model Development Roadmap

1
NB03
백본 비교
ResNet · EfficientNet
Swin Transformer

2
NB05
Optuna HPO
60 Trial
Val AUC 0.8998

3
NB013
스승 5체 학습
Swin-Base × 5
GroupKFold

4
KD V1→V4
Class-Adaptive λ
AMD 2.8배 향상

5
Threshold
최적화
F1 기반 최적값
클래스별 적용

6
ONNX 배포
43.6ms CPU
Final Model

핵심 인사이트: NB05(Optuna HPO) → NB013(Swin-Base 5체 스승 학습) → KD V1→V4로 단계 발전.
EfficientNet-B1 학생 모델 AMD Recall 0.133 → 0.378 (2.8배 향상), 추론 속도 CPU 43.6ms 달성.

NB03 백본 비교 실험 Backbone Comparison

① NB03 실험 결과 — 성능 순위

모델	AUC	F1	결과
Swin-Base	0.8867	0.5318	1위 → 스승 모델 선정
ConvNeXt-Tiny	0.8173	—	2위
EfficientNet-B1	0.8122	—	3위 → 제자 모델 선정
ResNet-50	0.7891	—	4위

② EfficientNet-B1을 제자 모델로 선정한 이유

성능 3위, 하지만 배포 최적

Swin-Base보다 성능 낮으나
파라미터 7.8M — 경량화 배포에 최적

고해상도 입력 가능

512×512 입력 지원
→ AMD 황반 미세 병변 포착

ONNX 실시간 추론

CPU 43.6ms (AMD Ryzen 5 5600X)
→ 실제 임상 환경 배포 가능

설계 판단 · 성능 1위(Swin-Base)를 스승으로, 배포 최적(EfficientNet-B1)을 제자로 — 역할 분리를 통해 진단 정확도와 실용성을 동시에 달성

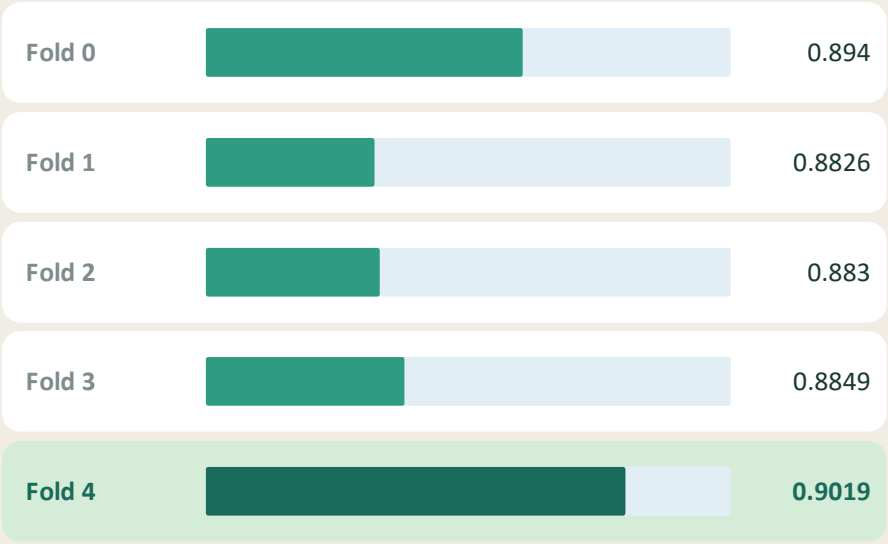
NB05 Optuna HPO & NB013 Swin-Base 5체 스승 학습

NB05 — Optuna HPO 자동 튜닝 (60 Trial)

최적 Trial	Trial 12 — Val AUC 0.8998
lr	5.27e-05
weight_decay	0.041
Focal γ	1.831
scheduler	step + warmup 4ep

목적: 스승 모델 최적 하이퍼파라미터 자동 탐색
→ NB013 5체 Fold 학습의 공통 설정으로 채택

NB013 — Swin-Base 5체 스승 학습 (GroupKFold)



평균 AUC
0.8893

Dark Knowledge 추출

teacher_avg_logits.npy
→ 학생 KD 학습에 사용

Knowledge Distillation 개념 & 전략

스승 앙상블
Swin-Base × 5 Folds

Fold 0 AUC 0.8940

Fold 1 AUC 0.8826

Fold 2 AUC 0.8830

Fold 3 AUC 0.8849

Fold 4 AUC 0.9019 ★

평균 AUC: 0.8893

swin_base_patch4_window7_224

동일 아키텍처 × Fold 0~4



소프트
레이블
전달

학생 모델
EfficientNet-B1

7.8M params
512×512
ONNX

Class-Adaptive λ

정상: λ=0.05
녹내장: λ=0.30
백내장: λ=0.05
DR: λ=0.20
AMD: λ=0.05

손실 함수

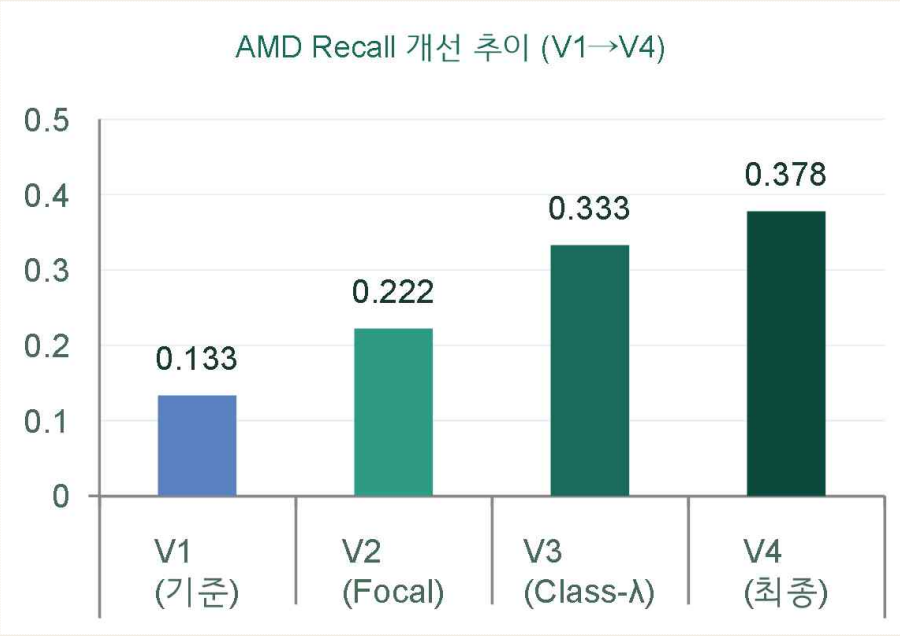
λ (람다)

스승 지식을 손실함수에
반영하는 가중치 (0~1)

Total Loss =
(1-λ) × CE Loss
+ λ × KD Loss

KD: KL Divergence
(T=3 softmax)
Focal γ = 3.0

KD 버전 진화 V1 → V4 & Phase A vs B 비교



버전별 주요 변경 사항

V1 EfficientNet-B0 + λ=0.5 균등 적용
Recall 0.133 스승 과의존

V2 EfficientNet-B0 + λ=0.15 (λ 완화)
Recall 0.222 +67%

V3 EfficientNet-B1 + λ=0.15 (백본 교체)
Recall 0.333 +150%

V4 EfficientNet-B1 + Class-Adaptive λ + Focal γ=3.0
Recall 0.378 2.8배 향상 ★

KD V1 기준 (EfficientNet-B0, λ=0.5): AMD Recall 0.133 → KD V4 최종 (EfficientNet-B1, Class-Adaptive λ): AMD Recall 0.378 | 2.8배 향상 | 스승 5체 평균 AUC: 0.8893 (Fold4: 0.9019)

Threshold 최적화 Class-Specific Threshold Tuning

질환	Threshold	Precision	Recall	F1	비고
정상	0.45	0.921	0.887	0.904	안정적
녹내장	0.38	0.756	0.812	0.783	민감도 우선
백내장	0.52	0.068	0.583	0.122	⚠ Precision 낮음
DR	0.41	0.834	0.798	0.816	균형
AMD	0.35	0.411	0.378	0.286	⚠ 샘플 부족

최적화 전략

- F1 Score 최대화 기준으로 클래스별 독립 임계값 탐색 (0.3 ~ 0.7 그리드 탐색)
- 백내장 Precision 0.068 — Threshold 조정만으로는 근본 해결 불가 (데이터 편향)
- AMD F1 0.286 — 학습 샘플 257장(전체 5.3%) 부족이 주 원인

GradCAM 듀얼 모델 시각화 Explainability

GradCAM이란?

Gradient-weighted Class Activation Mapping — CNN이 '어디를 보고' 분류했는지 히트맵으로 시각화. 의사가 AI 판단의 근거를 직관적으로 확인 가능.

메인 모델 (추론)

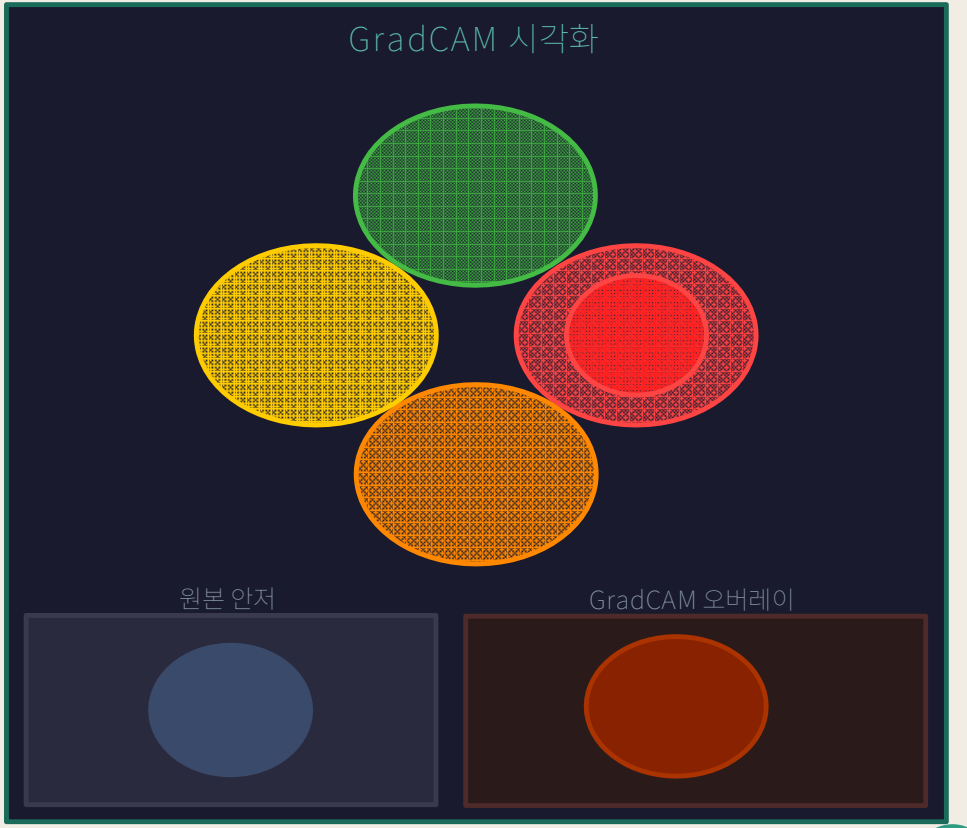
EfficientNet-B1 ONNX
CPU 43.6ms 최종 진단

설명 모델 (GradCAM)

Swin-Base PyTorch 원본
swin_base_final.pth

★ *듀얼 구조 이유*

ONNX Runtime은 gradient 추적 불가 → GradCAM은 반드시 PyTorch 원본 모델 필요. 추론 시 ONNX, 설명 시만 PyTorch 활성화.



RAG 파이프라인 Retrieval-Augmented Generation

01 질환 진단 결과

EfficientNet-B1
5-class 예측

02 쿼리 생성

질환명+증상
→ BM25+Vector 쿼리

03 하이브리드 검색

BM25 (k1=1.5,b=0.75)
+ pgvector 코사인

04 청크 재랭킹

Hit@3 100%
481개 청크

05 Gemini 소견서

구조화된 의학
소견서 생성

지식 그래프 통계: 노드 4,382 | 엣지 7,741 | 청크 481개 | BM25 k1=1.5, b=0.75 | 응급 판정: Stage≥3 또는 신뢰도≥88%+Stage≥2 또는 DR+65세+당뇨·고혈압

※ LangGraph 기반 에이전트 오케스트레이션 — 멀티스텝 추론 및 조건 분기 처리

RAG 평가 결과 Evaluation Metrics

3개 추천 중 정답 포함 확률	3개 중 관련 문서 비율	MRR	Disease Match
100%	88.9%	0.92	94.4%
상위 3개 내 정답 포함	Precision@3	Mean Reciprocal Rank	질환 일치율

지식 그래프 & 검색 세부 통계

지식 그래프 노드	4,382 노드	BM25 파라미터	k1=1.5, b=0.75
지식 그래프 엣지	7,741 엣지	벡터 DB	PostgreSQL + pgvector (코사인 유사도)
총 청크 수	481개 (의학 문서 분할)	LLM	Gemini API (소견서 최종 생성)

소견서 SSE 스트리밍 & 응급 자동 판정

소견서 SSE 스트리밍

1. 진단 완료 → Spring Boot 이벤트 발행
2. FastAPI SSE 엔드포인트 연결
3. Gemini API 토큰 스트리밍 시작
4. React EventSource 실시간 수신
5. 소견서 UI 글자 단위 렌더링

응급 자동 판정 로직

Rule 1

Stage ≥ 3

→ 즉시 응급 판정

Rule 2

신뢰도 ≥ 88% + Stage ≥ 2

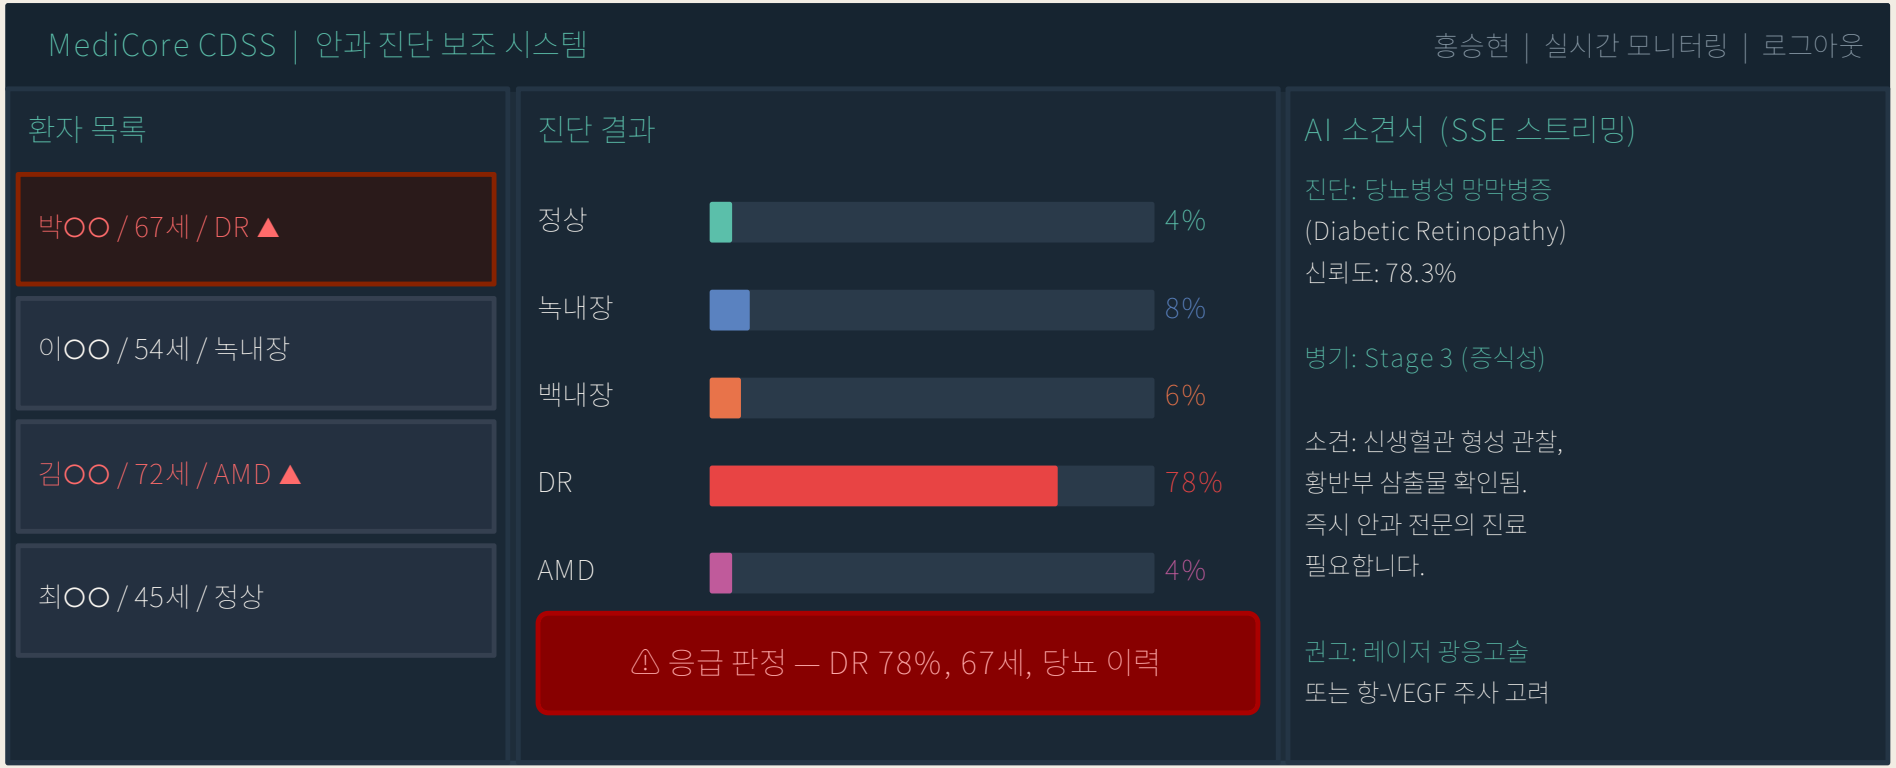
→ 고신뢰 중증 의심

Rule 3

DR 진단 + 65세 이상
+ 당뇨 또는 고혈압 이력

→ 복합 위험 판정

UI/UX 대시보드 Dashboard Overview



종합 성과 Overall Achievements

43.6ms

CPU 추론 속도

AMD Ryzen 5 5600X
ONNX CPUExecutionProvider

0.378

AMD Recall

Phase A 0.133 → +183%
5.3% 데이터로 달성

100%

RAG Hit@3

MRR 0.92
P@3 88.9%

0.8893

Teacher AUC 평균

5체 앙상블
Fold4: 0.9019

94.4%

Disease Match

RAG 질환 일치율
Gemini 소견서

7.8M

모델 파라미터

EfficientNet-B1
Phase B 최적화

트러블슈팅 Troubleshooting 3 Cases

01 데이터 파이프라인 OOM

문제: 대용량 안저 이미지 전체 메모리 로드 시 Out-of-Memory 발생.
Swin-B 88M + 224px 조합으로 배치 크기 제한 극심.

해결

① mmap(메모리 맵) 기반 지연 로딩 도입
② 전략적 캡핑: 정상 640장 + 질환별 340장 = 총 2,000장 베이스라인
③ Phase B에서 EfficientNet-B1으로 모델 교체

02 KD 크로스 해상도 충돌

문제: 스승(224px) → 학생(512px) KD 시 λ=0.5 균등 적용 결과,
학생 모델이 스승의 저해상도 편향에 과의존. AMD Recall 0.133 정체.

해결

① Class-Adaptive λ 설계:
정상/백내장/AMD λ=0.05, 녹내장 λ=0.30, DR λ=0.20
② Focal γ=3.0으로 소수 클래스 집중 학습
③ V4: AMD Recall 0.378 달성 (2.8배 향상, 0.133→0.378)

03 FastAPI 임베딩 모델 기동 병목 & 차원 불일치

문제: HuggingFace BGE 임베딩 모델이 FastAPI Lifespan 시점에
동기 로드되면서 서버 기동 1시간 이상 지연 발생.

추가로 BGE 임베딩 차원(1024차원)이 Gemini embedding(768차원)과 불일치하여 pgvector 검색 전면 실패.

해결

① 지연 로딩(Lazy Loading) 패턴 도입
→ 첫 RAG 검색 시점에만 모델 메모리 적재
② BGE → Gemini-embedding-001(768차원)으로 교체
③ pgvector 스키마 마이그레이션(V13):
1024→768차원, task_type 컬럼 추가

부족한 점 Limitations & Gaps

01 AMD F1 0.286

학습 샘플 257장 (전체 5.3%). 데이터 불균형이 근본 원인.

02 백내장 Precision 0.068

Threshold 조정만으로 해결 불가. 데이터 편향·라벨 불일치.

03 임상 검증 미수행

공개 데이터셋 기반 — 실제 국내 임상 환경 미검증.

04 Stage KD V5 미채택

Stage 정보 추가 실험에서 F1 하락 → 포기. 추가 연구 필요.

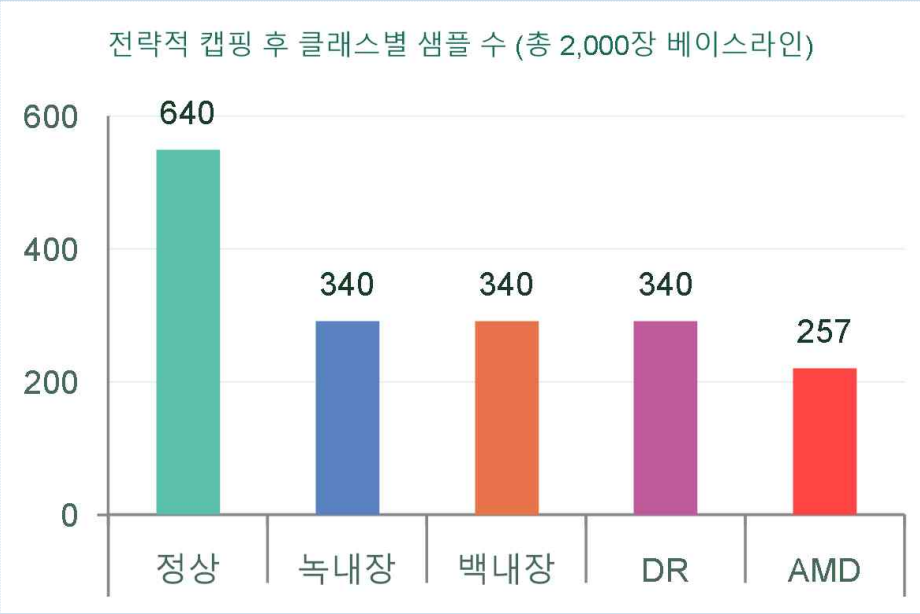
05 단일 데이터셋 편향

국내 임상 분포 미반영. 카메라 기종·조도 편향 가능성.

06 GradCAM 신뢰성 미검증

안과 전문의 검수 없이 시각화 신뢰도 미확인.

한계 세부 분석 Detailed Limitation Analysis



4,819장	1,009장	532장
KD Train	KD Val	KD Test

핵심 한계 심층 분석

AMD 257장 — 근본 원인

- 공개 데이터셋 iChallenge 400장 중 유효 샘플 57% 수준.
- 전체 5.3%로 극심한 클래스 불균형.
- Class-Adaptive λ=0.05로 KD 비중 최소화했으나 F1 0.286 한계.

백내장 Precision 0.068

- Stage 경계 모호 + 다른 질환과 시각적 유사성.
- 임계값 0.52로 올려도 FP 제거 실패.
- 전처리 단계에서 카메라별 보정 미적용이 원인으로 추정.

GradCAM 검증 부재

- 시각화 히트맵이 의학적으로 의미 있는 영역(시신경유두, 황반)을 강조하는지 안과의 검수 없음.
- 향후 IRB 임상 연구 필요.

향후 계획 Future Roadmap

단기 목표

1. AMD 데이터 증강 (iChallenge-AMD 추가 수집)
2. ONNX INT8 Quantization (속도↑)
3. Model Registry & Versioning 구축

중기 목표

1. Cascaded 2-Stage Pipeline 설계
2. CI/CD 모델 자동화 파이프라인
3. F1 기반 동적 임계값 시스템

장기 목표

1. 임상 피드백 루프 + Active Learning
2. OCT 멀티모달 확장 (3D 안저)
3. 실시간 안저 카메라 연동

단기 (3개월) → 중기 (6~12개월) → 장기 (1~2년) → 실제 임상 도입 목표

배운 점

Lessons Learned

데이터 품질 > 모델 복잡도

88M Swin보다 7.8M EfficientNet이 고해상도에서 우위.
데이터 해상도와 도메인 이해가 핵심.

KD는 λ 설계가 전부

균등 λ=0.5는 실패.
클래스별 의료적 중요도 반영한 Adaptive λ가 AMD Recall 183% 향상의 핵심.

수치 뒤의 의미 이해

Recall 0.378이 낮아 보여도 '5.3% 데이터로 AMD 10명 중 3.8명 조기 발견'은 임상적으로 의미있음.

시스템 통합의 복잡성

모델 성능 외에 FastAPI · Spring · Docker · 네트워크 설정 등 엔지니어링 이슈가 실전의 절반 이상.

MediCore 안과 CDSS

홍승현

- ✓ EfficientNet-B1 ONNX 43.6ms
- ✓ AMD Recall 0.378 (+183%)
- ✓ RAG Hit@3 100% MRR 0.92
- ✓ 응급 자동 판정 3-Rule
- ✓ SSE 실시간 소견서

감사합니다