PUMP SENSOR ANOMALY DETECTION

산업용 펌프 센서 이상 탐지 시스템

LSTM/CNN Autoencoder + Optuna 자동 튜닝 + RAG 기반 LLM 진단 리포트

발표자: 홍승현

2026. 04.20

주제 및 선정 이유

주 제

Pump Sensor Anomaly Detection

LSTM/CNN AE + Optuna 자동 튜닝 + RAG 기반 LLM 진단 리포트를 결합한 산업 장비 이상 탐지 시스템

선 정 이 유

1 모델 성능보다 설계 결정이 더 중요하다는 걸 검증

F2 지표 선택, bfill 제거, 시간순 분할 등 모델 구조보다 데이터를 어떻게 다루느냐가 결과에 더 큰 영향을 준다는 가설을 직접 체크

2 RAG가 실제로 쓸만한지 직접 검증

LLM을 그냥 API로 부르는 게 아니라, 내 탐지 결과와 도메인 문서를 연결하는 구조를 직접 구현하면 어떻게 되는지 확인

3 딥러닝 결과를 사람이 읽을 수 있게 만들려면?

모델이 '이상하다'고 출력하는 숫자를 어떻게 하면 사람이 바로 이해할 수 있는 진단 문장으로 바꿀 수 있는지 확인

4 Optuna 자동 튜닝이 실제로 얼마나 효과 있는지 의문

하이퍼파라미터를 바꾸는 게 아니라, 자동화된 탐색이 실제로 의미 있는 개선을 만드는지 숫자로 확인해보는 시도

결 과

설계 효과

설계 결정의 효과

동일 모델(LSTM-AE)에서 시간순 분할 + F2 적용 후 Val F2 0.23 → 0.44. 모델 바꾸지 않고 설계만 바꿨는데 수치가 달라짐

구현 결과

RAG 연동의 체감 효과

단순 Gemini 호출 대비, Top-3 센서 + 규정 문서를 프롬프트에 주입했을 때 리포트 구체성이 달라짐

XAI 구현

XAI

숫자를 말로 바꾸는 구조 피처별 MSE 역산 → Top-3 센서 → RAG 프롬프트 주입 → 자연어 진단. 모델 출력이 사람이 읽을 수 있는 문장이 됨

튜닝 수치

Optuna 튜닝의 실제 수치

VIF CNN: Val F2 0.11 → 0.41 (+0.30) All LSTM: Val F2 0.23 → 0.44 (+0.21)
자동 튜닝이 의미 있다는 걸 숫자로 직접 확인

목표 및 비즈니스 가정

핵심 가정

미탐(FN) 비용 ≫ 오탐(FP) 비용

이상을 놓치면 장비 파손·생산 중단으로 이어질 수 있어
Recall 최우선 방향으로 설계

이로 인한 설계 결정

1. 평가 지표: F2 Score (β=2) — Recall 가중
2. 모델 선정 기준: Val F2 최대화
3. Optuna 목적함수: Val F2 최대화
4. 전처리: bfill 제거 — 실시간 미래 참조 차단

프로젝트 목표

- 52개 센서 시계열에서 이상 구간 자동 탐지
- 딥러닝 3종 + 전통 ML 2종 비교 후 최선 모델 자동 선정
- VIF(21피처) vs 전체 센서(51피처) A/B 실험
- Optuna 500 trials 자동 튜닝 (TPE + Pruner)
- RAG + Gemini 진단 리포트 + Gradio UI 시연

* 비즈니스 가정(Recall 우선)에 맞춰 지표·튜닝·전처리를 일관되게 설계했습니다.

환경 설정

기술 스택

항목	내용
학습	Kaggle Notebook (GPU T4 x2)
로컬	Windows + VS Code + Python venv
프레임워크	PyTorch 2.x, Scikit-learn
튜닝	Optuna (TPE, MedianPruner)
LLM	Vertex AI Gemini (GCP 크레딧)
Vector DB	ChromaDB (로컬)
차트	Plotly (plotly_white)
시연	Gradio (share=True)

GPU 최적화 전략

기법	효과
AMP (Mixed Precision)	속도 1.5~2배, Tensor Core 활용
Window Cache 사전 생성	500 trials 윈도우 재생성 병목 제거
pin_memory=False, workers=0	CUDA DataLoader 충돌 방지
OPTUNA_TRAIN_EPOCHS=30	trial·Section 8 epoch 일치

GPU 최적화 효과

항목	CPU 기준	GPU + AMP + Cache
Optuna 500 trials	약 58시간	약 3시간 대
단축 비율	-	약 95% 감소

1 epoch ≈ 14초 × 30 epoch × 500 trials = 210,000초 (약 58시간)

→ GPU T4 x2 + AMP + Window Cache 적용으로 Kaggle 세션 12시간 제한 내 완주

데이터셋

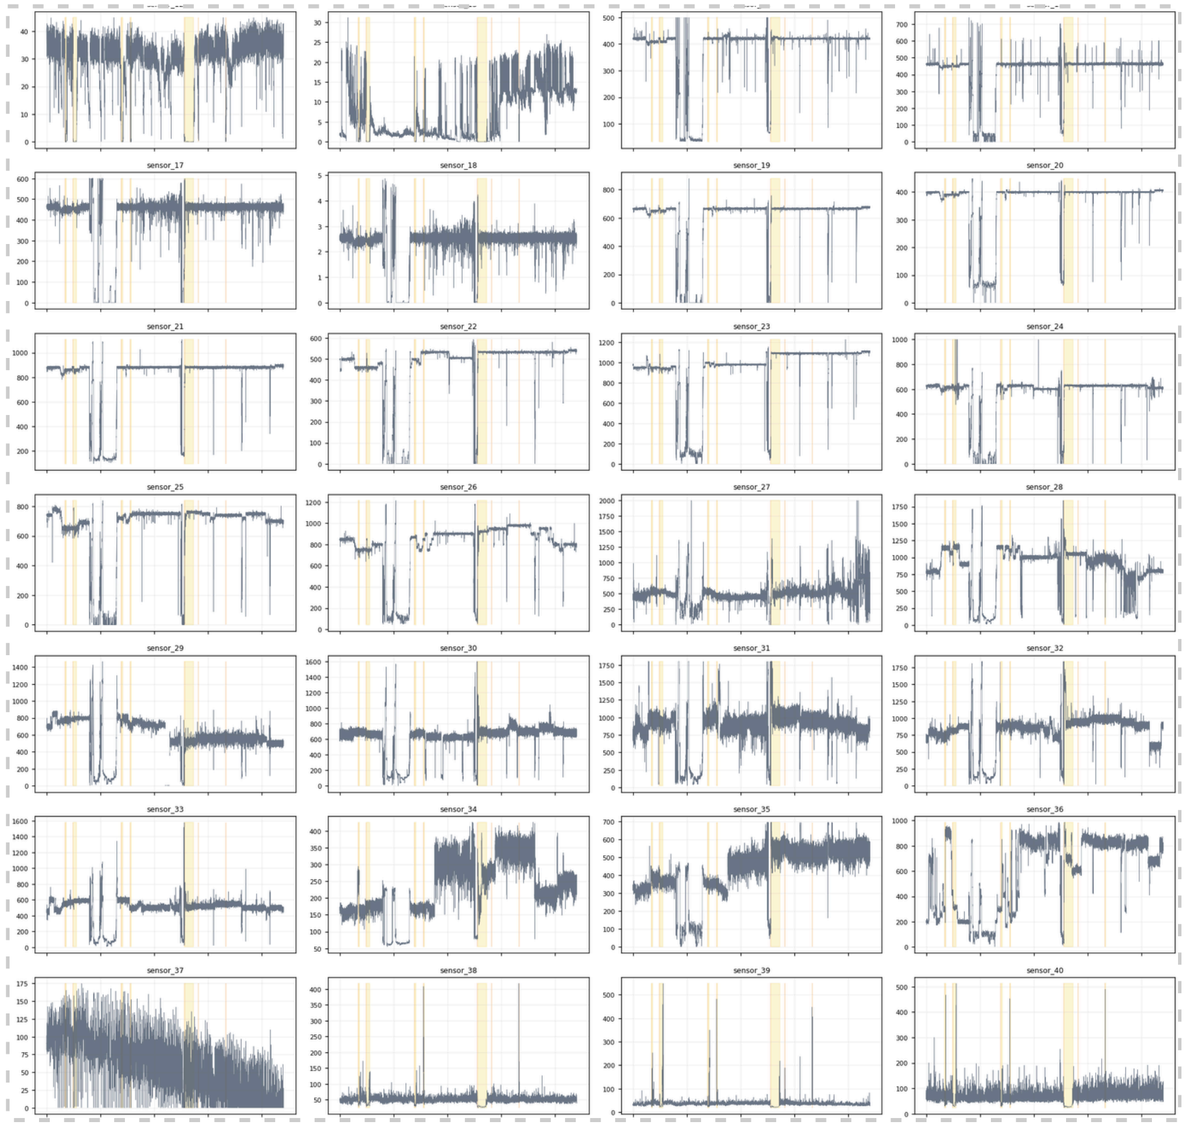
Kaggle — pump_sensor_data

항목	내용
전체 행 수	220,320 rows
기간	2018-04 ~ 2018-08 (1분 단위)
센서 채널	52개 (sensor_00 ~ sensor_51)
NORMAL	205,836 (93.4%)
RECOVERING	14,477 (6.6%)
BROKEN	7 (0.003%)
결측 컬럼	sensor_15 → 제거

핵심 특성

극단적 불균형 → 단순 분류 불가 → 비지도 학습 필요

시계열 시각화



전처리 과정

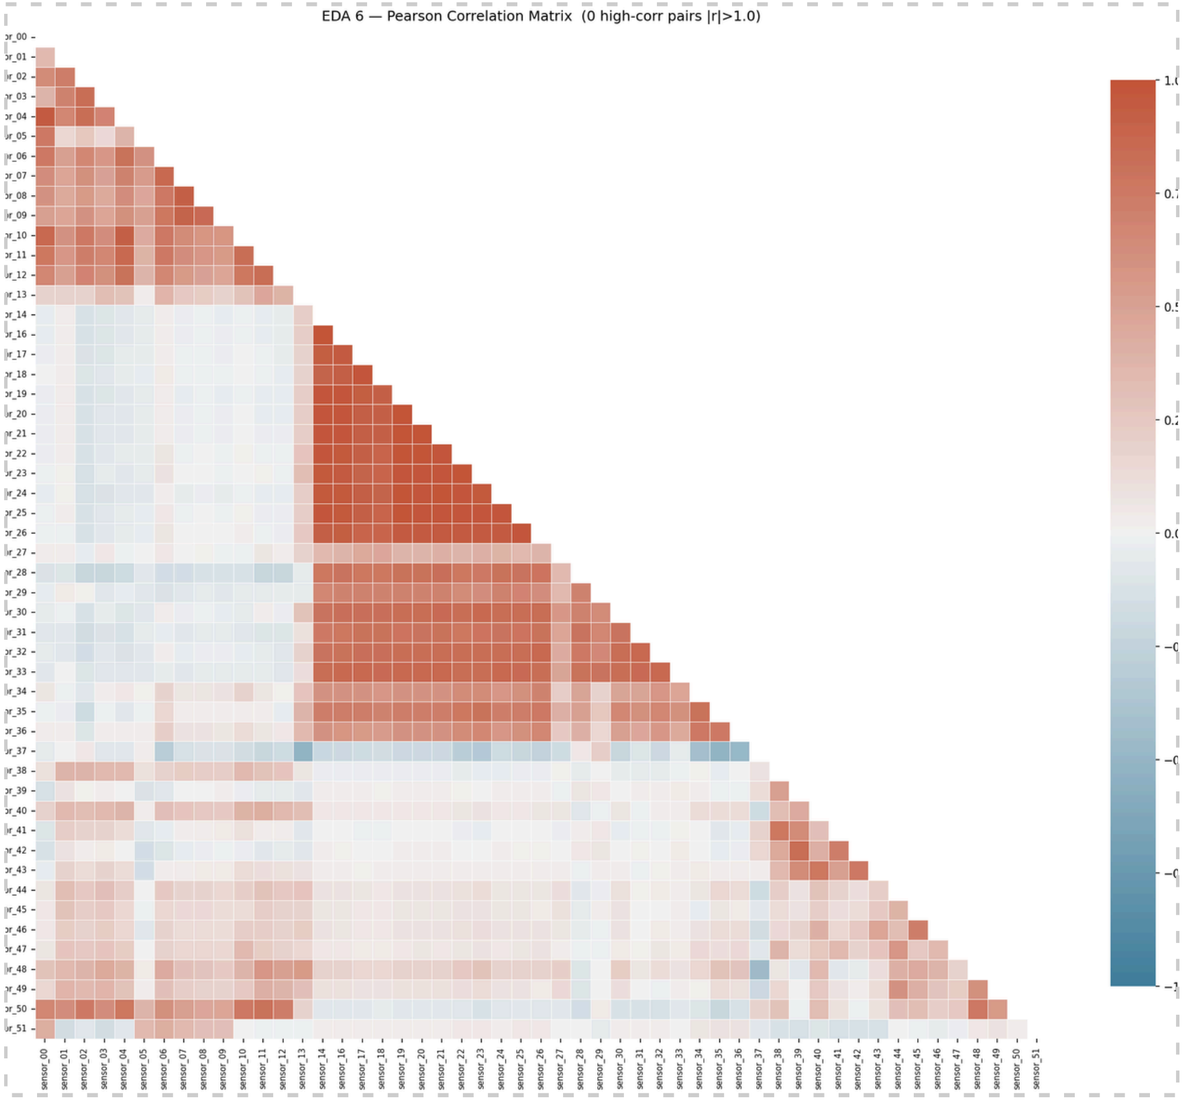
시간순 분할 (stratify 없음)

구간	비율	행 수	이상 비율
Train	55%	121,176	4.93%
Val	15%	33,048	25.52%
Test	30%	66,096	0.11%

전처리 파이프라인

- sensor_15 제거 (결측률 > 50%)
- VIF > 50 반복 제거 (VIF 버전만)
- ffill → fillna(0.0) — bfill 완전 제거
- MinMaxScaler — train 정상만 fit
- _safe_scaled (nan_to_num) — NaN/Inf 방어
- Sliding Window → WINDOW_CACHE 사전 생성

상관행렬 / PCA 시각화



모델 학습 과정

5종 모델 구조

딥러닝 3종

- **LSTM-AE** : Encoder LSTM → Latent → Decoder LSTM
- **CNN1D-AE** : Conv1D×2 → AdaptiveAvgPool → 복원
- **Transformer-AE** : Self-Attention 기반 Encoder/Decoder

베이스라인 2종

- **Isolation Forest** : 트리 기반 비지도 이상 탐지
- **One-Class SVM** : 정상 클래스 경계 학습

선정 기준

Val F2 (β=2) 최고 딥러닝 모델 자동 선정

Optuna 탐색 공간 (10종)

파라미터	탐색 범위
hidden	[32, 64, 128, 256]
latent	[8, 16, 32, 64]
n_layers	1~3 (CNN1D는 2 고정)
dropout	0.0 ~ 0.4
lr	1e-4 ~ 1e-2 (log)
weight_decay	1e-6 ~ 1e-3 (log)
batch	[32, 64, 128, 256]
optimizer	Adam / AdamW / RMSprop
threshold_pct	[90, 93, 95, 97, 99]
window_size	[30, 50, 100, 150]

1차 비교 분석 — VIF 버전 (21피처)

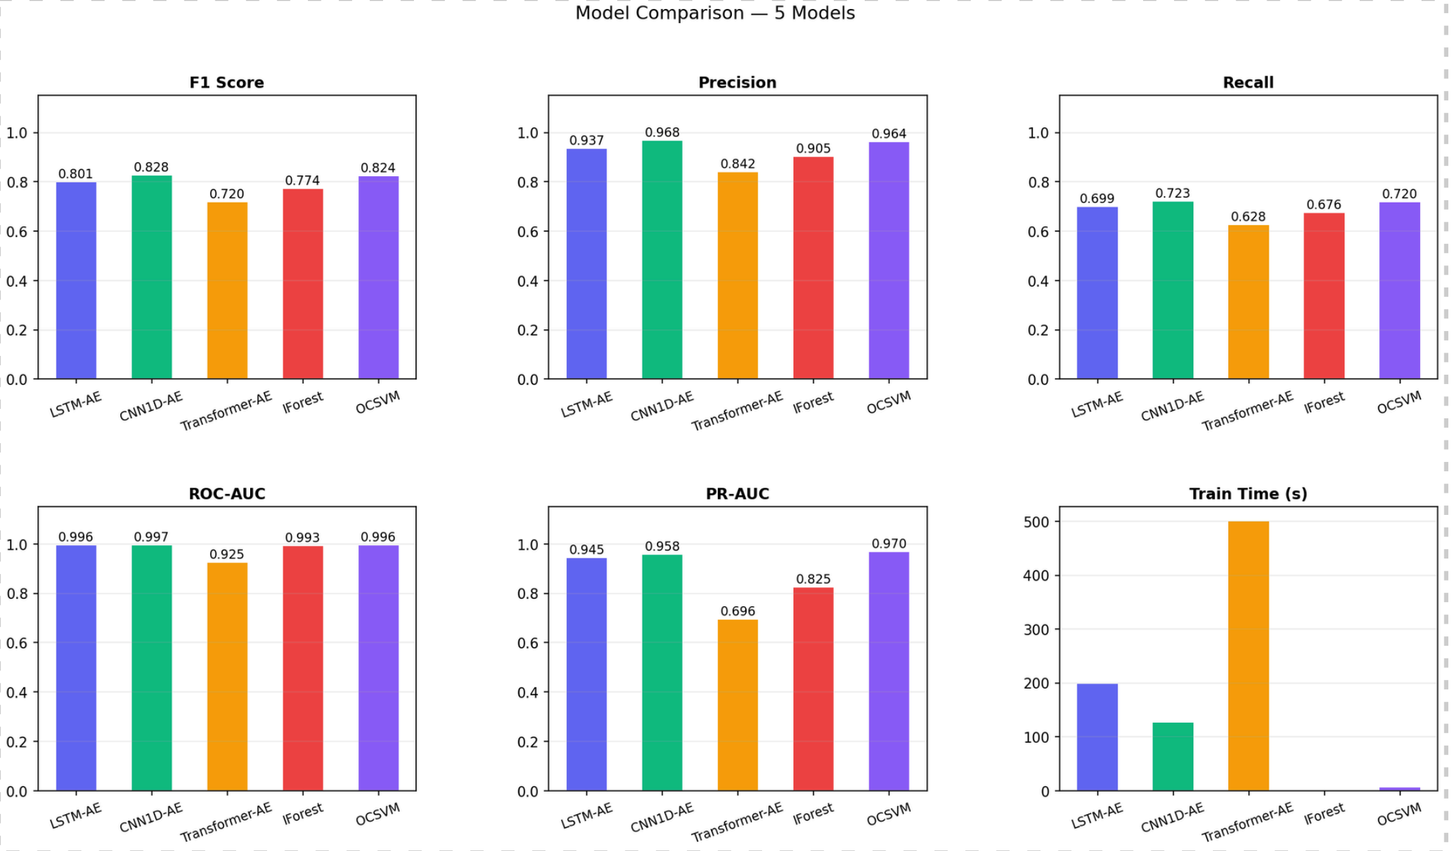
5종 모델 비교 (Test 기준, 참고용)

모델	Val F2	Test Recall	ROC-AUC
LSTM-AE	0.0839	0.7692	0.8732
CNN1D-AE ★	0.1104	0.8462	0.9234
Transformer-AE	0.0475	0.9231	0.9711
IForest	—	0.6154	0.8155
OCSVM	—	0.6923	0.8121

선정 결과

CNN1D-AE — Val F2=0.1104 최고 → Optuna 튜닝 대상

모델 비교 그래프



1차 모델 선정 + Optuna — CNN1D-AE

튜닝 결과

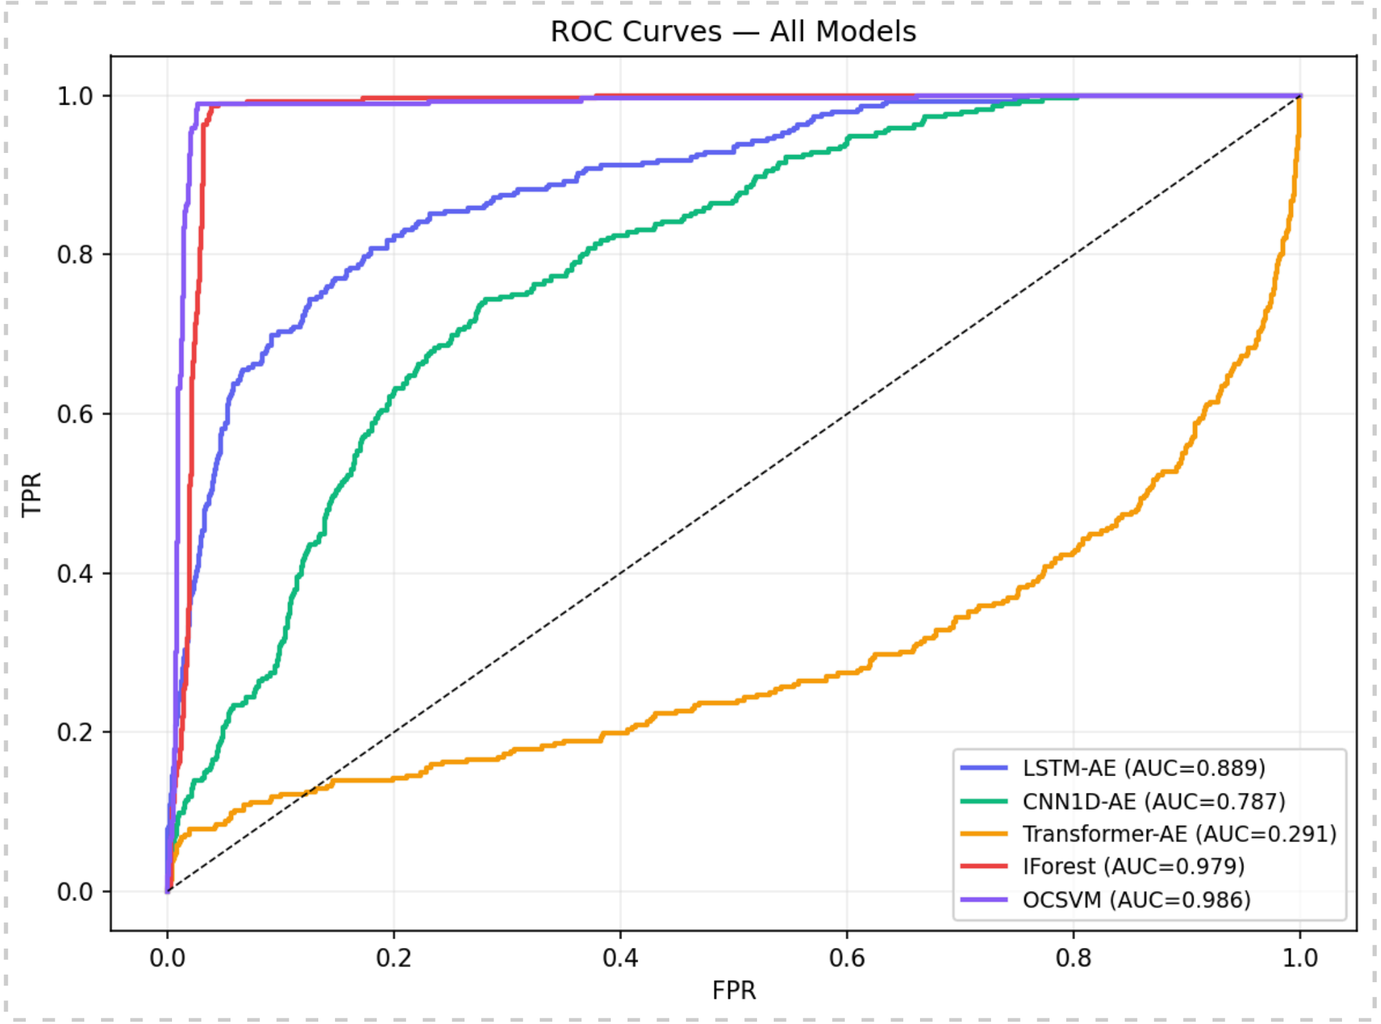
지표	디폴트(Val)	튜닝(Val)	향상
F2	0.1104	0.4112	+0.3008

지표	튜닝 후 Test (참고)
F2	0.0888
Recall	0.7222
ROC-AUC	0.8209

Best Params

hidden / latent	**128 / 8**
dropout / lr	**0.05 / 0.00696**
batch / optimizer	**256 / AdamW**
window_size	**100**
threshold_pct	**90**

Optuna 튜닝 히스토리



2차 비교 분석 — 전체 센서 (51피처)

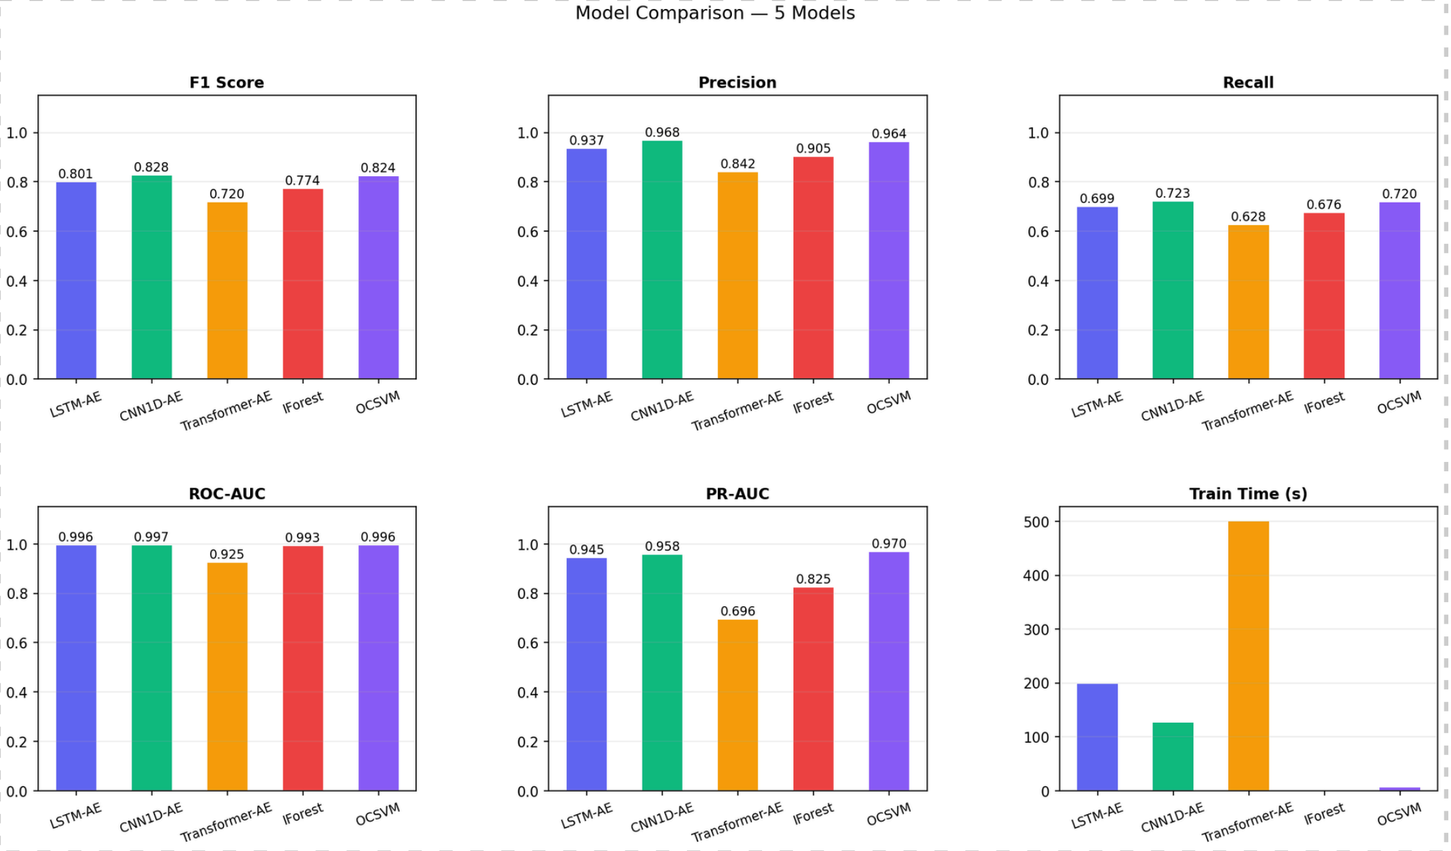
5종 모델 비교 (Test 기준, 참고용)

모델	Val F2	Test Recall	ROC-AUC
LSTM-AE ★	0.2292	0.9231	0.9442
CNN1D-AE	0.1887	0.9231	0.9412
Transformer-AE	0.2027	0.9231	0.9913
IForest	—	0.8462	0.8953
OCSVM	—	0.8462	0.9013

선정 결과

LSTM-AE — Val F2=0.2292 최고 → Optuna 튜닝 대상

모델 비교 그래프



2차 모델 선정 + Optuna - LSTM-AE

튜닝 결과

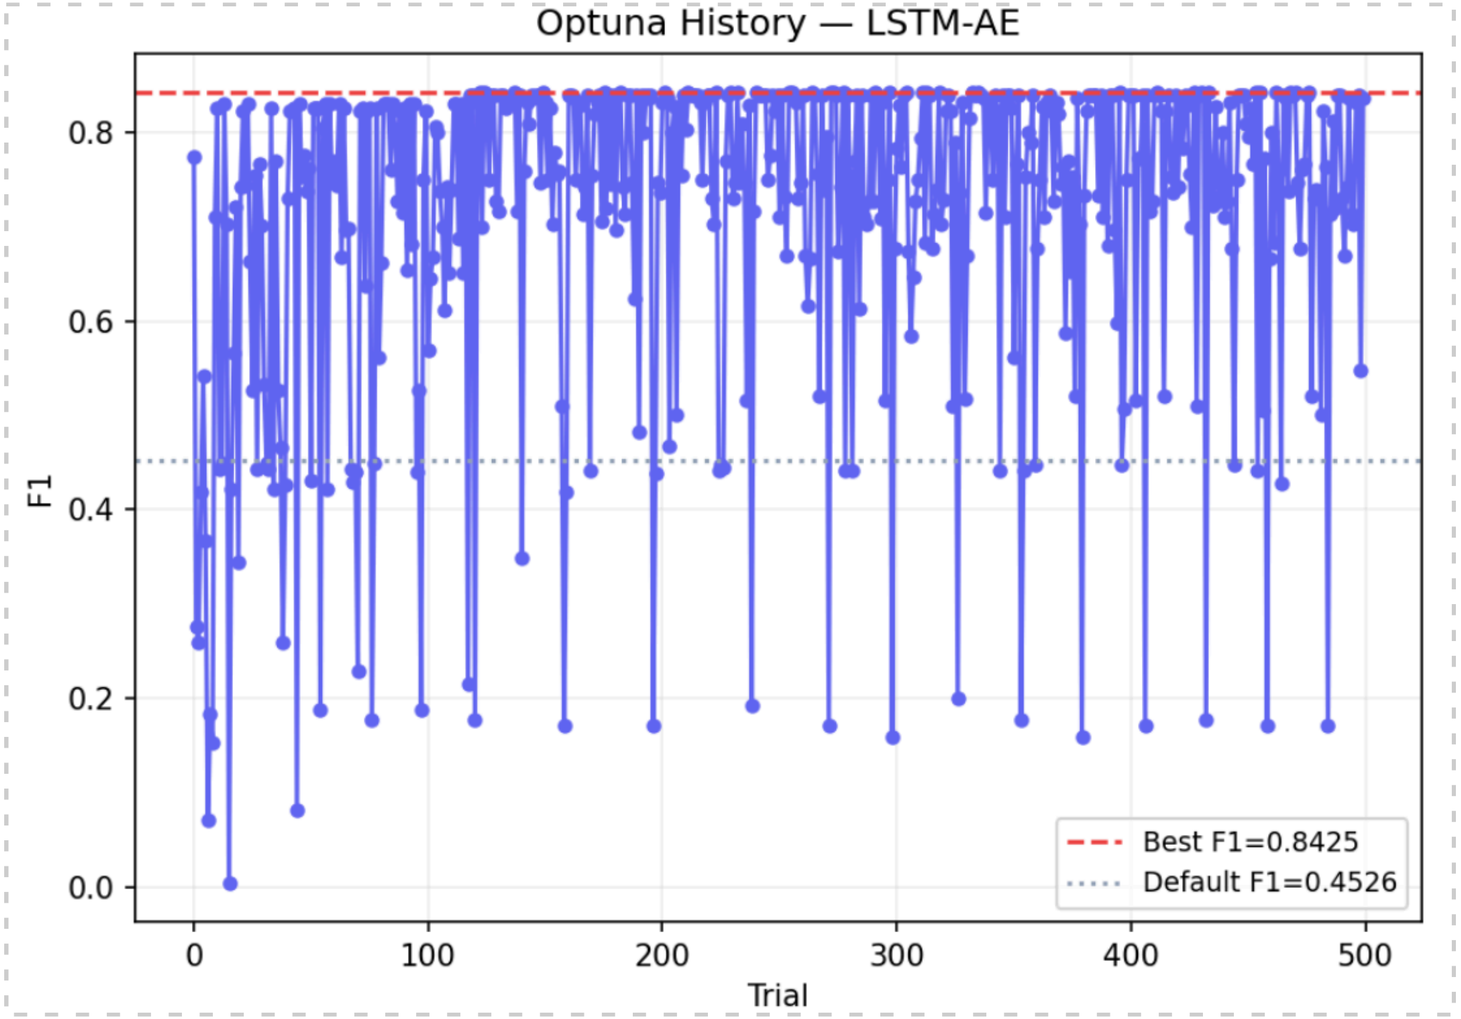
지표	디폴트(Val)	튜닝(Val)	향상
F2	0.2292	0.4441	+0.2149

지표	튜닝 후 Test (참고)
F2	0.0709
Recall	0.9091
ROC-AUC	0.9294

Best Params

hidden / latent	**32 / 8**
dropout / lr	**0.05 / 0.00122**
batch / optimizer	**128 / Adam**
window_size	**30**
threshold_pct	**90**

Optuna 튜닝 히스토리



2차 모델 선정 + Optuna - LSTM-AE

튜닝 결과

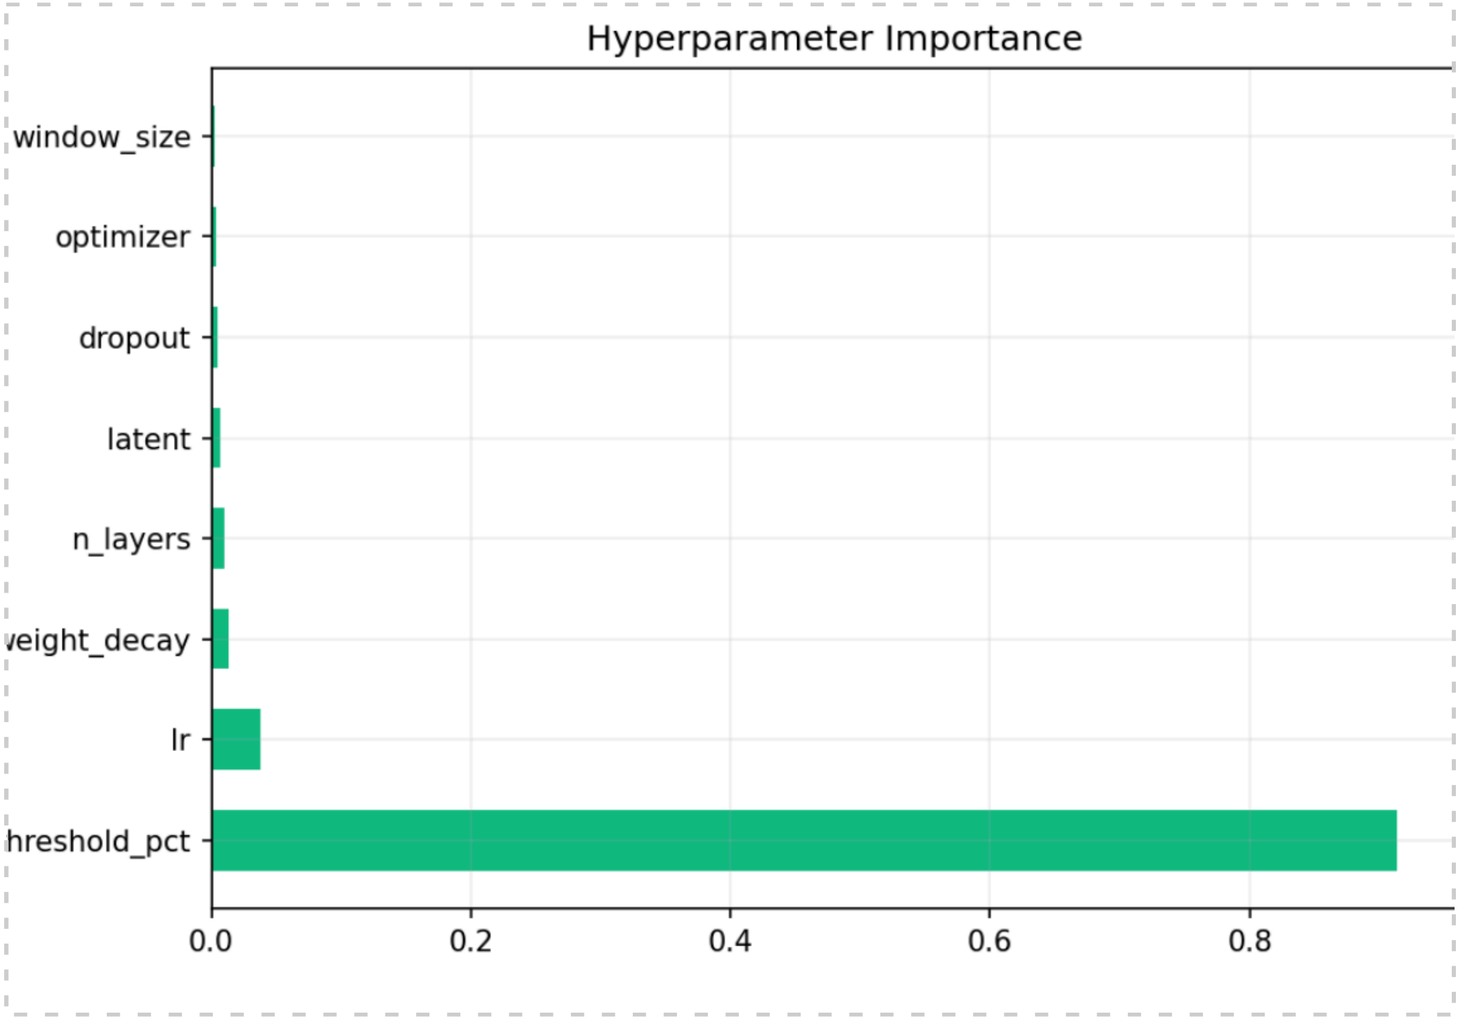
지표	디폴트(Val)	튜닝(Val)	향상
F2	0.2292	0.4441	+0.2149

지표	튜닝 후 Test (참고)
F2	0.0709
Recall	0.9091
ROC-AUC	0.9294

Best Params

hidden / latent	**32 / 8**
dropout / lr	**0.05 / 0.00122**
batch / optimizer	**128 / Adam**
window_size	**30**
threshold_pct	**90**

Optuna 튜닝 히스토리



A/B 테스트 — 최종 모델 확정

항목	VIF 버전 (CNN1D-AE)	전체 센서 버전 (LSTM-AE)
피처 수	21개 (경량)	51개 (정보 풍부)
디폴트 Val F2	0.1104	0.2292
튜닝 Val F2	0.4112	0.4441 ▲
튜닝 Test Recall	0.7222	0.9091 ▲
프리셋	vif (CNN1D-AE 권장)	all (LSTM-AE 권장)

챔피언 (Val F2 기준)

All-sensors LSTM-AE (Tuned)

Val F2 0.4441 / Test Recall 0.9091 — 미탐 방지 설계 목표와 일치

보조 모델

VIF CNN1D-AE (Tuned)

경량 배포·비교 근거 — VIF 피처 제거가 항상 성능 향상 아님을 A/B로 실증

최종 모델 스펙

항목	All-sensors LSTM-AE (챔피언)	VIF CNN1D-AE (보조)
피처 수	51개	21개
hidden	32	128
latent	8	8
layers	2	2
dropout	0.05	0.05
lr	0.00122	0.00696
optimizer	Adam	AdamW
threshold_pct	90	90
window_size	30	100
튜닝 Val F2	0.4441	0.4112
Test Recall	0.9091	0.7222
Test ROC-AUC	0.9294	0.8209

실제 구현

로컬 파이프라인 흐름

① sensor CSV 업로드 (Gradio)

② schema_validation → 피처 컬럼 정합 검사

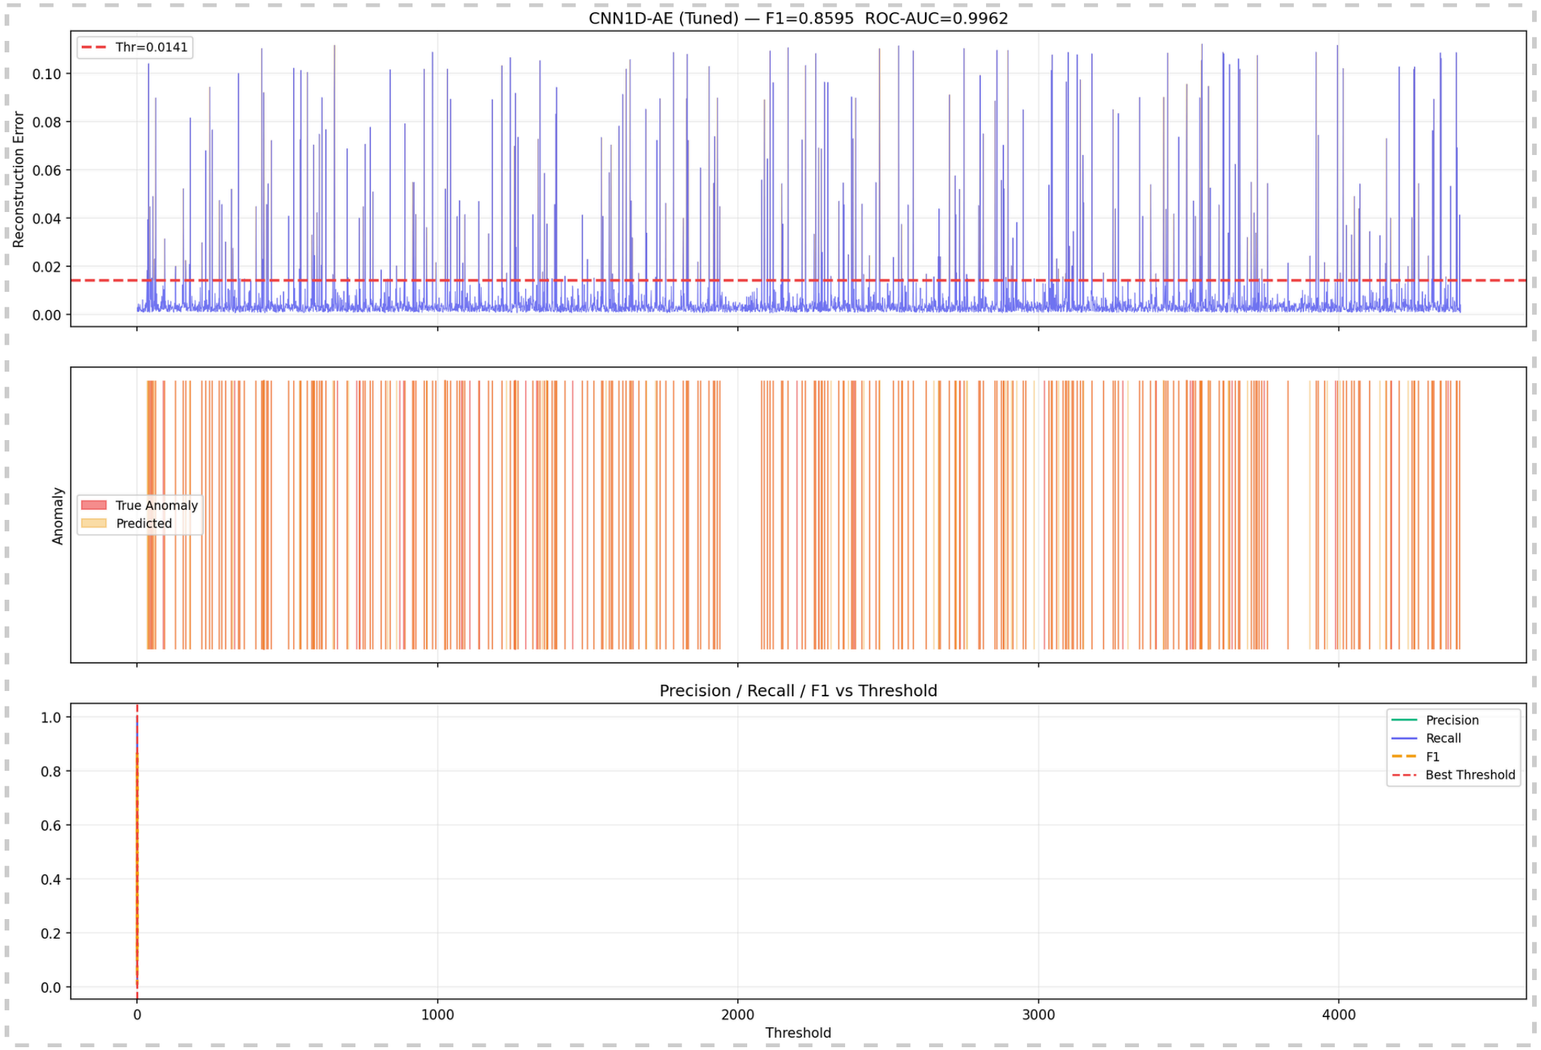
③ inference.py → 이상 탐지 + Top-3 의심 센서

④ rag_pipeline → ChromaDB + Gemini 리포트

⑤ light_grounding_check → 근거 점검 (PoC)

⑥ Gradio UI: Plotly 차트 + KPI + 리포트 출력

최종 탐지 결과



트러블슈팅

번호	문제	원인	해결
TS-01	VIF_THRESH=10 → 피처 7개, F1=0	산업 센서 공선성 과소평가	임계값 10→50 완화
TS-02	y_test anomaly 0%	이상이 앞 80%에 집중	시간순 55/15/30 분할 전환
TS-04	CPU Optuna 500 trials = 58시간	trial당 420초 × 500	GPU+AMP+Cache → 3시간대
TS-05	num_workers=2 → CUDA error	fork 후 CUDA 컨텍스트 충돌	num_workers=0
TS-09	pin_memory=True → RuntimeError	CUDA 텐서에 pin_memory 불가	pin_memory=False
TS-10	Optuna trial inf → 전체 중단	기울기 폭주 → inf	nan_to_num + catch=(ValueError,)
TS-17	튜닝 후 Test F2 < default	Val 최적화 ≠ Test 일반화	설계 특성으로 해석 + 보고서 명시

부족한 점

현재 한계

- **Val 최적화 vs Test 일반화 괴리**

  Optuna 목표=Val F2
  → Test에 과적합 가능. Test 이상 비율 0.11%로 신뢰도 제한.

- **비지도 학습 구조적 한계**

  임계값 설정에 민감. 정상 데이터만 학습
  → 경계 불명확.

- **XAI의 한계**

  Top-3 센서는 재구성 오차 기여도 기준.
  실제 물리적 고장 원인과 다를 수 있음.

- **light_grounding_check PoC 수준**

  문자열 일치만 검사. 완전한 환각 방지 아님.

향후 계획 (Future Work)

- N연속 알람 (Persistence Rule — 알람 피로도 완화)
- Vertex AI 임베딩 교체 (RAG 검색 품질 향상)
- 임계값 F2 기반 동적 최적화
- Hybrid Search (BM25 + Vector)
- Agentic RAG / GraphRAG
- MLOps (드리프트 감지 + 자동 재학습)
- Kafka 실시간 스트리밍 파이프라인

배운 점

- 비지도 AE의 원리와 한계 — 정상 패턴 학습 → 재구성 오차
- 미탐 비용 큰 도메인에서 F1보다 F2가 더 적합한 지표
- bfill은 실시간 환경에서 미래 참조 Leakage — 설계 단계부터 제거 필요
- VIF 임계값은 도메인 특성에 맞게 설정 (학술 기준 10이 항상 맞지 않음)
- VIF 제거가 항상 성능 향상이 아님 — A/B 실험으로 확인
- GPU DataLoader 설정 차이 (pin_memory, num_workers CUDA 충돌)
- Window Cache로 500 trials 병목 제거 — SW 엔지니어링 최적화
- 시계열 분할에서 val 이상 비율 확보가 지표 신뢰도의 핵심
- Optuna Val 최적화와 Test 일반화는 별개 — 두 지표를 분리해서 해석
- RAG는 근거 문서만으로 환각이 줄지 않음 — 구조화 입력 + 근거 점검 필요
- 딥러닝이 항상 ML보다 좋지 않으며 비즈니스 목표에 맞는 설계가 중요

PUMP SENSOR ANOMALY DETECTION

감사합니다.